

1. Anàlisi de tots els accidents

Anna Orteu

Contents

1 Dades	1
2 Estadístics	1
3 Resultats de l'estimació Diff-in-Diff per a les reclamacions ATT	5
3.1 Models sense covariables	5
3.1.1 Models de regressió TWFE i OLS	5
3.1.1.1 Variable Total	5
3.1.1.2 Variable Night	5
3.1.1.3 Variable Speed	6
3.1.1.4 Variable Urban	6
3.1.2 Estimació no paramètrica amb distribucions empíriques	7
3.1.2.1 Variable Total	7
3.1.2.2 Variable Night	7
3.1.2.3 Variable Speed	7
3.1.2.4 Variable Urban	8
3.2 Models amb covariables canviants en el temps	8
3.2.1 Model TWFE	8
3.2.1.1 Variable Total amb l'efecte de covariables	8
3.2.1.2 Variable Night amb l'efecte de covariables	12
3.2.1.3 Variable Speed amb l'efecte de covariables	17
3.2.1.4 Variable Urban amb l'efecte de covariables	21
3.2.2 Model semi-paramètric - Integració de propensity scores amb models Dif-in-Dif	25
3.2.2.1 Variable Total amb l'efecte de covariables	25
3.2.2.2 Variable Night amb l'efecte de covariables	25
3.2.2.3 Variable Speed amb l'efecte de covariables	25
3.2.2.4 Variable Urban amb l'efecte de covariables	25
3.3 Models amb covariables constants en el temps	26
3.3.1 Model TWFE	26

3.3.1.1	Variable Total amb l'efecte de covariables	26
3.3.1.2	Variable Night amb l'efecte de covariables	28
3.3.1.3	Variable Speed amb l'efecte de covariables	30
3.3.1.4	Variable Urban amb l'efecte de covariables	32
3.3.2	Models semi-paramètrics (IWE)	34
3.3.2.1	Variable Total amb l'efecte de covariables	35
3.3.2.2	Variable Night amb l'efecte de covariables	36
3.3.2.3	Variable Speed amb l'efecte de covariables	37
3.3.2.4	Variable Urban amb l'efecte de covariables	39
3.3.3	Models semi-paramètrics (IWE) amb dades balancejades	40
3.3.3.1	Variable Total amb l'efecte de covariables	41
3.3.3.2	Variable Night amb l'efecte de covariables	42
3.3.3.3	Variable Speed amb l'efecte de covariables	42
3.3.3.4	Variable Urban amb l'efecte de covariables	45

1 Dades

Es seleccionen només aquells individus que:

- Han conduït 100 quilòmetres o més en el període de pre-tractament
- No han declarat accidents en els períodes de pre i post tractament

Les variables d'interès són doncs:

- “Quilòmetres totals” (Total)
- “Percentatge de quilòmetres durant la nit” (Night)
- “Percentatge de distància conduïda per sobre de la velocitat” (Speed)
- “Percentatge de quilòmetres en àrees urbanes” (Urban)

I en total compte amb 6064 assegurats.

2 Estadístics

De les quals a continuació prenem els seus descriptius en el pre i post període:

Table 1: Telematics variables in pre-treatment period $t=1$

	Total	Night	Speed	Urban
Means	4694.7386	6.7023	8.4074	27.8237
STD	4677.8705	6.9342	8.7962	15.4425
Min	100.4160	0.0000	0.0723	0.0000
Q25	1306.4758	1.6372	2.5918	16.0602

Table 3: Means for pre and post-treatment periods by group

Time	D	Total	Time	D	Night
1	0	4693.403	1	0	6.6463
2	0	3256.540	2	0	6.7973
1	1	4707.992	1	1	7.2584
2	1	4089.594	2	1	7.4135

Table 4: Means for pre and post-treatment periods by group

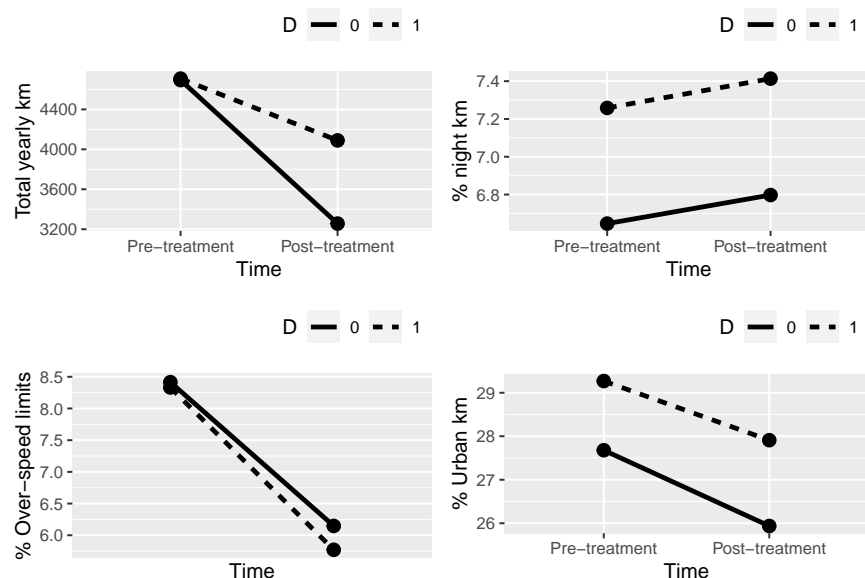
Time	D	Speed	time	Time	D	Urban
1	0	8.4150	1	1	0	27.6781
2	0	6.1473	2	2	0	25.9372
1	1	8.3312	1	1	1	29.2689
2	1	5.7707	2	2	1	27.9093

	Total	Night	Speed	Urban
Median	3273.0655	4.5814	5.2816	24.5263
Q75	6510.8150	9.7021	10.9821	36.6974
Max	39295.1860	60.3906	68.6549	95.9362
Kurtosis	1.9506	1.8043	2.1472	0.9486
Skewness	5.3704	4.5815	5.6431	0.7304

Table 2: Telematics variables in post-treatment period t=2

	Total	Night	Speed	Urban
Means	3332.7845	6.8537	6.1129	26.1177
STD	3149.6803	7.9181	7.2510	16.1126
Min	0.0000	0.0000	0.0000	0.0000
Q25	1060.0473	1.2569	1.6409	14.2636
Median	2482.4205	4.3128	3.6111	22.4300
Q75	4689.9253	9.8680	7.7456	34.5349
Max	34295.6730	100.0000	60.9904	100.0000
Kurtosis	1.9803	2.7066	2.5762	1.2323
Skewness	7.0360	15.6020	8.6906	1.8927

A continuació imprimim les mitjanes pels dos grups (control i tractament) i pels dos períodes (pre i post)



Pel que fa a la variable “Speed”, el seu gràfic té una fàcil interpretació. En tots dos cassos, tant si s’ha donat tractament com no el percentatge de quilòmetres recorreguts per sobre de la velocitat en el període de pre-tractament és major que en el post-tractament. Això pot ser degut a varis fenòmens, sent un dels principals, la introducció de varis radars en les vies urbanes. D’altra banda, la línia discontinua (amb tractament), es troba lleugerament inferior a la contínua, això indica que tal com esperat aquells individus que han patit algun accident, durant el següent any condueixen a menor velocitat, segurament degut a la por que han agafat al volant.

Pel que fa a la variable “Urban”, altre cop totes dues línies tornen a disminuir. Tanmateix, Aquest cop la línia que fa referència als individus que han tingut algun accident disminueix en menor mesura, indicant que aquests prefereixen recuperar la confiança al volant conduint per vies urbanes, segurament degut a que aquestes són més lentes.

Pel que fa a la variable “Night”, totes dues línies tenen una tendència ascendent similar. Tanmateix, sí que es pot notar que la línia discontinua es troba en tot moment per sobre, indicant que clarament aquells que condueixen amb major freqüència durant la nit, tenen una probabilitat major de tenir algun accident.

Finalment la variable “Total” és la més difícil d’explicar en tenir un comportament contrari a l’esperat. En aquest es veu clarament que el fet d’haver tingut un accident dona lloc a realitzar més quilòmetres. El fet que la unitat de mesura siguin els quilòmetres i no un percentatge, per exemple, pot ser una de les raons d’aquesta extranya conclusió.

D’altra banda, també s’afegiran les següents covariables als models:

- age= edat de l’assegurat
- age35= 1 si l’edat ≤ 35 (primer quartil aproximadament), = 0 altrament
- age_lic= edat de la llicència de conduir
- age_lic15= 1 si l’edat _lic ≤ 15 (primer quartil aproximadament), = 0 altrament
- parking_yes= 1 si s’utilitza pàrquing durant la nit, = 0 altrament
- woman= 1 si l’assegurada és una dona, = 0 altrament
- BMzones= 1 si la zona de conducció és Barcelona o Madrid, = 0 altrament

- power100= 1 si la potència del cotxe és ≤ 100 , = 0 altrament

Les variables edat i anys de llicència s’han binaritzat a nivells que s’han considerat rellevants per a poder realitzar un anàlisi en funció de valors concrets. S’han provat altres quartils i talls, però aquest ha estat el més encertat. Així doncs, durant els models no s’utilitzaran les variables numèriques com a tal, sinó les seves corresponents categòriques.

En les següents taules s’imprimeixen els descriptius estadístics de les covariables. Com que s’observen canvis en els períodes de pre i post tractament, s’assumirà que són covariables canviants en el temps durant els models.

Com a observació, fer notar que tenint en compte que sempre s’agafa l’edat a l’inscriure un primer registre i després es manté el mateix valor al llarg del temps, així com per la llicència de conduir, un es podria preguntar com és que les estadístiques d’aquestes variables poden canviar al llarg del temps. Així com la variable **woman**, ja que la única manera de canviar el sexe seria que la persona es fes pròpiament un canvi de sexe. Bé doncs, aquests cassos es donen generalment perquè es canvia el titular de la pòlissa, mantenint totes les altres característiques intactes.

Table 5: Covariates in pre-treatment period t=1

	age	age35	lic_age	lic_age15	parking_yes	woman	BMzones	power100
Means	37.8238	0.1723	17.5761	0.2010	0.6784	0.4715	0.1436	0.5935
STD	2.7727	0.3777	2.7888	0.4008	0.4671	0.4992	0.3507	0.4912
Min	31.1836	0.0000	13.0466	0.0000	0.0000	0.0000	0.0000	0.0000
Q25	35.7507	0.0000	15.3199	0.0000	0.0000	0.0000	0.0000	0.0000
Median	37.7425	0.0000	17.1233	0.0000	1.0000	0.0000	0.0000	1.0000
Q75	39.9212	0.0000	19.4096	0.0000	1.0000	1.0000	0.0000	1.0000
Max	45.4384	1.0000	42.4575	1.0000	1.0000	1.0000	1.0000	1.0000
Kurtosis	0.0495	1.7348	0.6729	1.4917	-0.7638	0.1143	2.0317	-0.3806
Skewness	-0.7218	1.0098	0.5678	0.2251	-1.4168	-1.9873	2.1281	-1.8554

Table 6: Covariates in post-treatment period t=2

	age	age35	lic_age	lic_age15	parking_yes	woman	BMzones	power100
Means	37.8373	0.1774	17.5746	0.2004	0.6994	0.4987	0.1405	0.5777
STD	2.8122	0.3821	2.8013	0.4003	0.4586	0.5000	0.3475	0.4940
Min	29.5288	0.0000	11.3068	0.0000	0.0000	0.0000	0.0000	0.0000
Q25	35.7144	0.0000	15.3151	0.0000	0.0000	0.0000	0.0000	0.0000
Median	37.7795	0.0000	17.0795	0.0000	1.0000	0.0000	0.0000	1.0000
Q75	40.0144	0.0000	19.4438	0.0000	1.0000	1.0000	0.0000	1.0000
Max	47.2329	1.0000	28.2767	1.0000	1.0000	1.0000	1.0000	1.0000
Kurtosis	0.0068	1.6882	0.5509	1.4968	-0.8694	0.0053	2.0685	-0.3144
Skewness	-0.7576	0.8501	-0.4617	0.2404	-1.2443	-2.0003	2.2791	-1.9014

Tanmateix, varis dels mètodes amb que es treballa durant aquest projecte requereixen de covariables constants en el temps. Així doncs, es seleccionaran només aquells registres que tinguin aquestes covariables constants.

Table 7: Covariates in pre-treatment period t=1

	age	age35	lic_age	lic_age15	parking_yes	woman	BMzones	power100
Means	37.9511	0.1573	17.7626	0.1772	0.6528	0.4933	0.1458	0.5855
STD	2.7369	0.3641	2.7509	0.3819	0.4762	0.5000	0.3529	0.4927
Min	31.1836	0.0000	13.0466	0.0000	0.0000	0.0000	0.0000	0.0000
Q25	35.9315	0.0000	15.5699	0.0000	0.0000	0.0000	0.0000	0.0000
Median	37.9123	0.0000	17.4411	0.0000	1.0000	0.0000	0.0000	1.0000
Q75	40.0370	0.0000	19.6219	0.0000	1.0000	1.0000	0.0000	1.0000
Max	44.4630	1.0000	26.1507	1.0000	1.0000	1.0000	1.0000	1.0000
Kurtosis	-0.0117	1.8818	0.4776	1.6903	-0.6415	0.0270	2.0070	-0.3471
Skewness	-0.7510	1.5417	-0.5418	0.8575	-1.5889	-1.9998	2.0284	-1.8800

Table 8: Covariates in post-treatment period t=2

	age	age35	lic_age	lic_age15	parking_yes	woman	BMzones	power100
Means	37.9511	0.1573	17.7626	0.1772	0.6528	0.4933	0.1458	0.5855
STD	2.7369	0.3641	2.7509	0.3819	0.4762	0.5000	0.3529	0.4927
Min	31.1836	0.0000	13.0466	0.0000	0.0000	0.0000	0.0000	0.0000
Q25	35.9315	0.0000	15.5699	0.0000	0.0000	0.0000	0.0000	0.0000
Median	37.9123	0.0000	17.4411	0.0000	1.0000	0.0000	0.0000	1.0000
Q75	40.0370	0.0000	19.6219	0.0000	1.0000	1.0000	0.0000	1.0000
Max	44.4630	1.0000	26.1507	1.0000	1.0000	1.0000	1.0000	1.0000
Kurtosis	-0.0117	1.8818	0.4776	1.6903	-0.6415	0.0270	2.0070	-0.3471
Skewness	-0.7510	1.5417	-0.5418	0.8575	-1.5889	-1.9998	2.0284	-1.8800

En aquest cas queden 4075 assegurats al conjunt filtrat.

3 Resultats de l'estimació Diff-in-Diff per a les reclamacions ATT

3.1 Models sense covariables

3.1.1 Models de regressió TWFE i OLS

Estimem l' ATT_2 definit com:

$$ATT_2 = E[Y_{i2}(1) - Y_{i2}(0) | D_i = 1]. \quad (1)$$

utilitzant els models de regressió TWFE i OLS sense covariables

3.1.1.1 Variable Total

Table 9: TWFE for Total variable

	Estimate	Std. Error	t-value	Pr(> t)	R2
Tr	818.4658	243.7359	3.358	8e-04	0.5425

Table 10: OLS for Total variable

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	6130.2665	120.0352	51.0706	0.0000
Time	-1436.8631	75.9169	-18.9268	0.0000
D	14.5883	177.4421	0.0822	0.9345
Tr	818.4658	250.9411	3.2616	0.0011

3.1.1.2 Variable Night

Table 11: TWFE for Night variable

	Estimate	Std. Error	t-value	Pr(> t)	R2
Tr	0.0041	0.4411	0.0093	0.9926	0.5573

Table 12: OLS for Night variable

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	6.4953	0.2242	28.9752	0.0000
Time	0.1510	0.1418	1.0651	0.2869
D	0.6120	0.3314	1.8469	0.0648
Tr	0.0041	0.4686	0.0088	0.9930

3.1.1.3 Variable Speed

Table 13: TWFE for Speed variable

	Estimate	Std. Error	t-value	Pr(> t)	R2
Tr	-0.2929	0.3854	-0.76	0.4473	0.7177

Table 14: OLS for Speed variable

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	10.6827	0.2428	43.9889	0.0000
Time	-2.2677	0.1536	-14.7643	0.0000
D	-0.0838	0.3590	-0.2334	0.8154
Tr	-0.2929	0.5077	-0.5769	0.5640

3.1.1.4 Variable Urban

Table 15: TWFE for Urban variable

	Estimate	Std. Error	t-value	Pr(> t)	R2
Tr	0.3813	0.7156	0.5328	0.5942	0.7416

Table 16: OLS for Urban variable

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	29.4191	0.4752	61.9070	0.0000
Time	-1.7409	0.3006	-5.7924	0.0000
D	1.5908	0.7025	2.2645	0.0236
Tr	0.3813	0.9935	0.3838	0.7011

Amb aquests primers resultats notem que l'efecte del tractament només és estadísticament significatiu per la variable **Total**, amb signe positiu. Això indica que extranyament, com més accidents es tenen, més quilòmetres s'acaben duen a terme durant el següent any després d'haver tingut l'accident.

Pel que fa a la interpretació dels models, fer notar que el coeficient **Time** pel cas en que es realitza el model amb OLS (per a **Total**), és igual a -1436.8631, perquè és el resultat de fer 3256.540 (T=2, D=0) - 4693.403 (T=1, D=0), que serien els dos primers valors de les taules que mostraven les mitjanes pels períodes de pre i post tractament, per grups. D'altra banda, el coeficient de D, 14.5883, prové de fer 4707.992 (T=1, D=1) - 4693.403 (T=1, D=0). Finalment, el coeficient de **Tr** prové de 4089.594 (T=2, D=1) - 3256.540 (T=2, D=1) + 14.5883.

Tanmateix, en realitat se sap que el fet de tenir un accident no és completament aleatòri, sinó que és aleatòri, condicionat a unes característiques. Així doncs més endavant es realitzarà models similars però afegint covariables.

3.1.2 Estimació no paramètrica amb distribucions empíriques

Aquest mètode és una generalització del Dif-in-Dif anomenat Changes-in-Changes. Com a fets rellevants, assumeix que les característiques no són observables, però que dins de cada grup (control i tractament), la distribució d'aquestes característiques no canvia al llarg del temps. És per aquest raó, que tot i no treballar amb covariables en aquest model, s'ha treballat amb el conjunt de dades reduït, el que mostra les covariables constants al llarg del temps.

Com a exercici extra en comparació als altres mètodes, s'ha decidit calcular també els quartils.

Els resultats mostren clarament que cap de les variables dependents dona lloc a un pvalor significatiu, raó per la qual no es pot dir res sobre aquests estimadors. Aquests resultats no sorprenen en haver detectat al llarg de tot el projecte que els estimadors no paramètrics o semi-paramètrics no són una bona opció per a aplicar a aquestes dades. Concretament, el problema està en que aquestes són massa desbalancejades, és a dir, existeixen molts més usuaris a la base de dades que no han tingut cap accident, que usuaris amb accidents, dificultant molt que models d'aquest tipologia puguin distingir correctament.

3.1.2.1 Variable Total

```
## Quartils 0.25 0.5 0.75 : -0.153 -0.639 -1.368
```

Table 17: Changes-in-changes for Total variable

	ATT_2	sd	z_stat	p_value	CI_lower	CI_upper
2-tails	-87.9167	376.452	-0.2335	0.8153	-825.749	649.9155
1-tail	-87.9167	376.452	-0.2335	0.4077	-Inf	531.2916

3.1.2.2 Variable Night

Quartils 0.25 0.5 0.75 : -0.0005723753 -0.001024203 -0.002405078

Table 18: Changes-in-changes for Night variable

	ATT_2	sd	z_stat	p_value	CI_lower	CI_upper
2-tails	-0.0108	0.5207	-0.0208	0.9834	-1.0315	1.0098
1-tail	-0.0108	0.5207	-0.0208	0.4917	-Inf	0.8457

3.1.2.3 Variable Speed

Quartils 0.25 0.5 0.75 : -0.002877485 -0.004806799 -0.02099104

Table 19: Changes-in-changes for Speed variable

	ATT_2	sd	z_stat	p_value	CI_lower	CI_upper
2-tails	-0.0226	0.7027	-0.0321	0.9744	-1.3999	1.3548
1-tail	-0.0226	0.7027	-0.0321	0.4872	-Inf	1.1333

3.1.2.4 Variable Urban

Quartils 0.25 0.5 0.75 : -0.008177116 -0.04099969 -0.001335072

Table 20: Changes-in-changes for Urban variable

	ATT_2	sd	z_stat	p_value	CI_lower	CI_upper
2-tails	-0.023	1.2064	-0.0191	0.9848	-2.3875	2.3414
1-tail	-0.023	1.2064	-0.0191	0.4924	-Inf	1.9612

3.2 Models amb covariables canviants en el temps

3.2.1 Model TWFE

Aquest model amb totes les covariables així com aquestes al temps $t = 2$ i canviant en el temps s'està referint a la següent formulació:

$$Y_{it} = \alpha_i + \delta_t + \tau \cdot Tr_{it} + \beta \cdot X_{it} \cdot I(t = 2) + \gamma \cdot X_{it} \cdot Tr_{it} + \delta \cdot X_{it} + \epsilon_{it}, \quad (2)$$

3.2.1.1 Variable Total amb l'efecte de covariables En primer lloc creem el model amb tots els efectes additius i multiplicatius de les covariables. Es pot clarament observar que no tots els components del model són significatius en tenir pvalors molt superiors al 0.05 (agafant un nivell de confiança del 95%). Concretament, les interaccions creades entre les covariables i Tr semblen clarament ser no significatives. Així doncs, s'ha decidit seleccionar el millor model maximitzant l'R quadrat ajustat. El resultat del millor model mostra un valor estimat per ATT_2 positiu i significatiu al 0.09%. Aquesta millora s'ha hagut de fer manualment, el qual implica que sempre pot haver-hi major tendència a errors.

Table 21: TWFE for Total variable with covariates

	Estimate	Std. Error	t-value	Pr(> t)	R2	R2Adj
Tr	800.4120	563.1053	1.4214	0.1552	0.5465	0.09
age35	127.2525	275.3050	0.4622	0.6439	0.5465	0.09
age35_2	-271.2564	228.3853	-1.1877	0.2350	0.5465	0.09
lic_age15	-412.7710	254.9081	-1.6193	0.1054	0.5465	0.09
lic_age15_2	162.6168	219.5563	0.7407	0.4589	0.5465	0.09
parking_yes	929.0184	257.0805	3.6137	0.0003	0.5465	0.09
parking_yes2	-686.6278	169.0524	-4.0616	0.0000	0.5465	0.09
woman	-732.9228	206.2766	-3.5531	0.0004	0.5465	0.09
woman_2	218.7486	163.8448	1.3351	0.1819	0.5465	0.09
BMzones	-528.8030	451.1723	-1.1721	0.2412	0.5465	0.09
BMzones_2	274.4212	217.6779	1.2607	0.2075	0.5465	0.09
power100	-230.0002	216.6729	-1.0615	0.2885	0.5465	0.09
power100_2	30.9797	166.8933	0.1856	0.8527	0.5465	0.09
Tr:age35_2	91.8772	701.0373	0.1311	0.8957	0.5465	0.09
Tr:lic_age15_2	253.1422	669.3358	0.3782	0.7053	0.5465	0.09
Tr:parking_yes2	-61.3778	527.5085	-0.1164	0.9074	0.5465	0.09
Tr:woman_2	-345.7381	504.1764	-0.6857	0.4929	0.5465	0.09
Tr:BMzones_2	70.2823	683.2903	0.1029	0.9181	0.5465	0.09
Tr:power100_2	255.7215	508.8650	0.5025	0.6153	0.5465	0.09

Table 22: TWFE for Total variable with covariates

	Estimate	Std. Error	t-value	Pr(> t)	R2	R2Adj
Tr	807.3561	243.0341	3.3220	0.0009	0.546	0.091
lic_age15	-360.3023	218.4160	-1.6496	0.0991	0.546	0.091
parking_yes	975.3139	255.3572	3.8194	0.0001	0.546	0.091
parking_yes2	-706.2360	159.2244	-4.4355	0.0000	0.546	0.091
woman	-799.2458	199.7551	-4.0011	0.0001	0.546	0.091
woman_2	221.5632	151.6239	1.4613	0.1440	0.546	0.091

Altrament, també hauríem pogut decidir agafar l'AIC com a criteri de selecció del millor model. Existeix una funció `stepAIC()` que selecciona el millor model donat el model complet. Tanmateix, aquesta requereix crear un model lineal (`lm`) com fet a continuació.

Abans de crear el model, centrarem els valors de les variables, encara que les covariables siguin binàries, perquè així ho requereix el model. A més a més, com que s'han de centrar a 0 totes les covariables introduïdes, creem també una variable per a les interaccions que es volen introduir en el model. S'ha decidit centrar les variables, perquè aquest procés dona lloc al mateix resultat que incloure variables fictícies (*dummy*) pels afectes fixos, però evita haver d'introduir tantes variables en el model amb les qual a vegades R no és ni capaç de tractar. A més a més, com més variables s'introdueixen en el model, major robustesa es perd.

Com podem observar, els coeficients obtinguts són exactament iguals que els obtinguts amb la funció `plm`, sent les significacions d'aquests (*p*valors) el que canvia de forma poc notòria. Així doncs, a partir d'ara es treballarà amb aquest model en ser més fàcil d'optimitzar. Així mateix, amb aquest tipus de model s'ha de tenir en compte que l'R quadrat ajustat fa referència a les variables centrades (transformades). Així doncs, s'ha de calcular altre cop aquesta mesura de forma manual per a obtenir un resultat fiable d'aquest ajust. Com a últim comentari sobre aquesta manera de construir el model, dir que el fet d'optimitzar, com es farà a continuació, de forma automàtica, pot implicar que la variable "Tr" s'elimini d'aquest. Això s'ha d'evitar en tot moment en ser el seu coeficient el que dona el valor de l' ATT_2 .

Table 23: TWFE for Total variable with covariates

	Estimate	Std. Error	t value	Pr(> t)	R2	R2Adj	AIC
Tr	800.4120	397.8301	2.0119	0.0442	0.5495	0.0961	226320.4
age35	127.2525	194.5011	0.6543	0.5130	0.5495	0.0961	226320.4
age35_2	-271.2564	161.3527	-1.6811	0.0928	0.5495	0.0961	226320.4
lic_age15	-412.7710	180.0908	-2.2920	0.0219	0.5495	0.0961	226320.4
lic_age15_2	162.6168	155.1150	1.0484	0.2945	0.5495	0.0961	226320.4
parking_yes	929.0184	181.6257	5.1150	0.0000	0.5495	0.0961	226320.4
parking_yes2	-686.6278	119.4344	-5.7490	0.0000	0.5495	0.0961	226320.4
woman	-732.9228	145.7330	-5.0292	0.0000	0.5495	0.0961	226320.4
woman_2	218.7486	115.7553	1.8898	0.0588	0.5495	0.0961	226320.4
BMzones	-528.8030	318.7503	-1.6590	0.0971	0.5495	0.0961	226320.4
BMzones_2	274.4212	153.7880	1.7844	0.0744	0.5495	0.0961	226320.4
power100	-230.0002	153.0779	-1.5025	0.1330	0.5495	0.0961	226320.4
power100_2	30.9797	117.9090	0.2627	0.7928	0.5495	0.0961	226320.4
age35_2_Tr	91.8772	495.2782	0.1855	0.8528	0.5495	0.0961	226320.4
lic_age15_2_Tr	253.1422	472.8813	0.5353	0.5924	0.5495	0.0961	226320.4
parking_yes2_Tr	-61.3778	372.6812	-0.1647	0.8692	0.5495	0.0961	226320.4
woman_2_Tr	-345.7381	356.1973	-0.9706	0.3317	0.5495	0.0961	226320.4
BMzones_2_Tr	70.2823	482.7401	0.1456	0.8842	0.5495	0.0961	226320.4
power100_2_Tr	255.7215	359.5098	0.7113	0.4769	0.5495	0.0961	226320.4

Com a resultat del millor model obtingut després de l’optimització prèviament esmentada, es conclou inicialment que és homogeni perquè no hi ha efectes interactius entre les variables. Pel que fa a l’efecte del tractament, ATT_2 , aquest és positiu i significatiu, indicant que aquells usuaris que han tingut una accident passen a recórrer més quilòmetres totals, després de tenir-lo, que aquells que no n’han tingut cap.

L’efecte de les variables a $t=2$ és la suma de la variable + variable_2. Així doncs, per exemple l’efecte de la variable parking_yes a $t=2$ és significativa i positiva. Això implica que aquells usuaris que tenen pàrquing, recorren més quilòmetres totals, el qual té molt sentit ja que generalment són aquells que tenen més diners i que per tant es poden permetre més gasolina i més quilòmetres. Tanmateix, la variable parking_yes2 en realitat mostra un efecte negatiu. Això indica que l’efecte entre $t=1$ i $t=2$ s’ha reduït, és a dir, que durant el primer període es recorrien molts més quilòmetres totals si es tenia pàrquing, mentre aquest efecte tot i que continua sent positiu, ha disminuït durant el segon període.

Contràriament, les dones recorren menys quilòmetres totals que els homes, tot i que la diferència entre homes i dones es redueix durant el període de post-tractament. També recorren menys quilòmetres totals aquells que s’han tret el carnet fa menys de 15 anys. La variable BMzones, que recordem que és = 1 si la zona de conducció és Barcelona o Madrid i 0 altrament, també té un efecte negatiu a $t=2$ però aquest no és significatiu, tot i que millori l’explicació del model.

Table 24: TWFE for Total variable with reduced covariates

	Estimate	Std. Error	t value	Pr(> t)	R2	R2Adj	AIC
Tr	815.3623	171.8530	4.7445	0.0000	0.5491	0.0967	226305.8
lic_age15	-330.2755	155.1279	-2.1291	0.0333	0.5491	0.0967	226305.8
parking_yes	931.3211	181.3547	5.1354	0.0000	0.5491	0.0967	226305.8
parking_yes2	-696.8813	112.7775	-6.1793	0.0000	0.5491	0.0967	226305.8
woman	-742.8234	144.9557	-5.1245	0.0000	0.5491	0.0967	226305.8
woman_2	208.5263	107.3896	1.9418	0.0522	0.5491	0.0967	226305.8
BMzones	-530.9050	317.5070	-1.6721	0.0945	0.5491	0.0967	226305.8
BMzones_2	281.5846	146.3098	1.9246	0.0543	0.5491	0.0967	226305.8

	Estimate	Std. Error	t value	Pr(> t)	R2	R2Adj	AIC
power100	-207.3325	141.4845	-1.4654	0.1428	0.5491	0.0967	226305.8

Només com a comprovació, fer notar que de fet l'R quadrat ajustat que haguèssim obtingut si haguèssim posat aquestes variables en el model plm és millor (major), indicant que utilitzar funcions és més fiables, raó per la qual a partir d'ara s'utilitzaran models lm per a aquest propòsit:

Table 25: TWFE for Total variable with covariates

	Estimate	Std. Error	t-value	Pr(> t)	R2	R2Adj
Tr	815.3623	243.1473	3.3534	0.0008	0.5463	0.0911
lic_age15	-330.2755	219.4836	-1.5048	0.1324	0.5463	0.0911
parking_yes	931.3211	256.5908	3.6296	0.0003	0.5463	0.0911
parking_yes2	-696.8813	159.5639	-4.3674	0.0000	0.5463	0.0911
woman	-742.8234	205.0914	-3.6219	0.0003	0.5463	0.0911
woman_2	208.5263	151.9408	1.3724	0.1700	0.5463	0.0911
BMzones	-530.9050	449.2266	-1.1818	0.2373	0.5463	0.0911
BMzones_2	281.5846	207.0073	1.3603	0.1738	0.5463	0.0911
power100	-207.3325	200.1801	-1.0357	0.3004	0.5463	0.0911

Com a analizi extra, s'ha volgut mirar quina variable és més important per a saber el nombre total de quilòmetres recorreguts d'un assegurat, l'edat o els anys que fa que pot conduir. El model deixant únicament la variable `lic_age15` és exactament el mateix que quan teníem totes dues variables, mentre al deixar únicament l'edat, aquesta ha "reemplaçat" el lloc de `lic_age15` en el model, en trobar exactament els mateixos coeficients i magnituds, amb significacions lleugerament diferents. No obstant això, tot i que la variable `age35` apareix en el model aquesta és clarament no significativa, mentre la variable `lic_age15` sí que presentava un coeficient significatiu. Això indica que tot i que es necessita una mesura del temps en el model, els anys de llicència permeten aproximar amb més precisió els quilòmetres totals recorreguts pels assegurats.

Table 26: TWFE for Total variable with reduced covariates without `lic_age15`

	Estimate	Std. Error	t value	Pr(> t)	R2	R2Adj	AIC
Tr	819.6395	171.8453	4.7696	0.0000	0.5492	0.0969	226307.9
age35_2	-202.4363	130.0292	-1.5569	0.1195	0.5492	0.0969	226307.9
parking_yes	935.7181	181.3462	5.1598	0.0000	0.5492	0.0969	226307.9
parking_yes2	-685.4251	113.0504	-6.0630	0.0000	0.5492	0.0969	226307.9
woman	-749.1139	144.9453	-5.1683	0.0000	0.5492	0.0969	226307.9
woman_2	211.2827	107.4133	1.9670	0.0492	0.5492	0.0969	226307.9
BMzones	-557.0888	317.4161	-1.7551	0.0793	0.5492	0.0969	226307.9
BMzones_2	292.4147	146.4098	1.9972	0.0458	0.5492	0.0969	226307.9
power100	-230.0755	140.9145	-1.6327	0.1026	0.5492	0.0969	226307.9

Table 27: TWFE for Total variable with reduced covariates without age35

	Estimate	Std. Error	t value	Pr(> t)	R2	R2Adj	AIC
Tr	815.3623	171.8530	4.7445	0.0000	0.5491	0.0967	226305.8
lic_age15	-330.2755	155.1279	-2.1291	0.0333	0.5491	0.0967	226305.8
parking_yes	931.3211	181.3547	5.1354	0.0000	0.5491	0.0967	226305.8
parking_yes2	-696.8813	112.7775	-6.1793	0.0000	0.5491	0.0967	226305.8
woman	-742.8234	144.9557	-5.1245	0.0000	0.5491	0.0967	226305.8
woman_2	208.5263	107.3896	1.9418	0.0522	0.5491	0.0967	226305.8
BMzones	-530.9050	317.5070	-1.6721	0.0945	0.5491	0.0967	226305.8
BMzones_2	281.5846	146.3098	1.9246	0.0543	0.5491	0.0967	226305.8
power100	-207.3325	141.4845	-1.4654	0.1428	0.5491	0.0967	226305.8

3.2.1.2 Variable Night amb l'efecte de covariables El model complet amb totes les covariables i interaccions possibles, així com la seva reducció dona lloc als següents resultats. En aquest cas s'ha obtingut un valor molt proper a 0 i no significatiu per l' ATT_2 , indicant doncs que no implica cap diferència en el percentatge d'hores conduïdes durant la nit el fet d'haver patit un accident durant l'any anterior o no. Pel que fa als coeficients sense interaccions comentar que la variable **age35** presenta un efecte positiu. Això indica que els usuaris amb menys de 35 anys condueixen un percentatge de quilòmetres major durant la nit que els majors de 35 anys, tot i que aquest percentatge es redueix durant el segon període. També es pot observar que tenir pàrquing i conduir per Madrid o Barcelona augmenta aquest percentatge de conducció nocturna, mentre ser dona o tenir un cotxe amb baixa potència el disminueix.

D'altra banda, es nota que s'ha inclòs varies interaccions entre la covariables i la variable **Tr**. Per aquestes s'ha decidit calcular l' ATT_2 associat dels quals només el de la variable **power100** ha resultat ser significatiu amb una significació del 3,5%, mentre **lic_age15** i **parking_yes** presenten un pvalor superior al 5% de significància. A més a més, el valor resultant ha estat rarament positiu. Això és degut, tal com veiem a la gràfica, que aquells que augmenten el percentatge de quilòmetres conduïts durant la nit del primer al segon període són els usuaris que condueixen cotxes grans que no han tingut cap accident i els usuaris amb cotxes de baixa potència que han tingut algun accident. Mentre els altres dos tipus d'usuaris disminueixen el percentatge. És a dir, la diferència entre $t=1$ i $t=2$ disminueix pels usuaris que condueixen cotxes grans, independentment de si han tingut un accident o no, mentre aquesta augmenta pels usuaris que condueixen cotxes de baixa potència.

Table 28: TWFE for Night variable with covariates

	Estimate	Std. Error	t value	Pr(> t)	R2	R2Adj	AIC
Tr	0.6255	0.7170	0.8723	0.3831	0.562	0.1212	73055.32
age35	1.5221	0.3506	4.3417	0.0000	0.562	0.1212	73055.32
age35_2	-1.1314	0.2908	-3.8903	0.0001	0.562	0.1212	73055.32
lic_age15	0.1953	0.3246	0.6018	0.5473	0.562	0.1212	73055.32
lic_age15_2	-0.0116	0.2796	-0.0415	0.9669	0.562	0.1212	73055.32
parking_yes	1.0956	0.3274	3.3467	0.0008	0.562	0.1212	73055.32
parking_yes2	-0.2792	0.2153	-1.2972	0.1946	0.562	0.1212	73055.32
woman	-2.6873	0.2627	-10.2307	0.0000	0.562	0.1212	73055.32
woman_2	0.8012	0.2086	3.8404	0.0001	0.562	0.1212	73055.32
BMzones	-0.6565	0.5745	-1.1427	0.2532	0.562	0.1212	73055.32
BMzones_2	0.8627	0.2772	3.1124	0.0019	0.562	0.1212	73055.32
power100	-0.2020	0.2759	-0.7320	0.4642	0.562	0.1212	73055.32
power100_2	-0.7506	0.2125	-3.5321	0.0004	0.562	0.1212	73055.32
age35_2_Tr	-1.1078	0.8927	-1.2410	0.2146	0.562	0.1212	73055.32


	Estimate	Std. Error	t value	Pr(> t)	R2	R2Adj	AIC
lic_age15_2_Tr	-1.5725	0.8523	-1.8450	0.0651	0.562	0.1212	73055.32
parking_yes2_Tr	-1.1269	0.6717	-1.6776	0.0935	0.562	0.1212	73055.32
woman_2_Tr	0.1639	0.6420	0.2553	0.7985	0.562	0.1212	73055.32
BMzones_2_Tr	-0.5505	0.8701	-0.6327	0.5269	0.562	0.1212	73055.32
power100_2_Tr	1.1836	0.6480	1.8266	0.0678	0.562	0.1212	73055.32

Table 29: TWFE for Night variable with reduced covariates

	Estimate	Std. Error	t value	Pr(> t)	R2	R2Adj	AIC
Tr	0.6711	0.6572	1.0212	0.3072	0.5619	0.1222	73045.43
age35	1.5971	0.3290	4.8546	0.0000	0.5619	0.1222	73045.43
age35_2	-1.2378	0.2567	-4.8219	0.0000	0.5619	0.1222	73045.43
parking_yes	1.0100	0.3135	3.2213	0.0013	0.5619	0.1222	73045.43
woman	-2.7319	0.2543	-10.7416	0.0000	0.5619	0.1222	73045.43
woman_2	0.8216	0.1990	4.1282	0.0000	0.5619	0.1222	73045.43
BMzones_2	0.7639	0.2575	2.9661	0.0030	0.5619	0.1222	73045.43
power100_2	-0.7750	0.1957	-3.9597	0.0001	0.5619	0.1222	73045.43
lic_age15_2_Tr	-1.8673	0.7655	-2.4393	0.0147	0.5619	0.1222	73045.43
parking_yes2_Tr	-1.4154	0.6409	-2.2085	0.0272	0.5619	0.1222	73045.43
power100_2_Tr	1.1956	0.6266	1.9079	0.0564	0.5619	0.1222	73045.43

Table 30: Some effects

	lic_age15	parking_yes	power100
coef	-1.1962	0.2657	1.0917
Z	-1.2608	0.4417	1.8010
p_value	0.1037	0.3293	0.0358



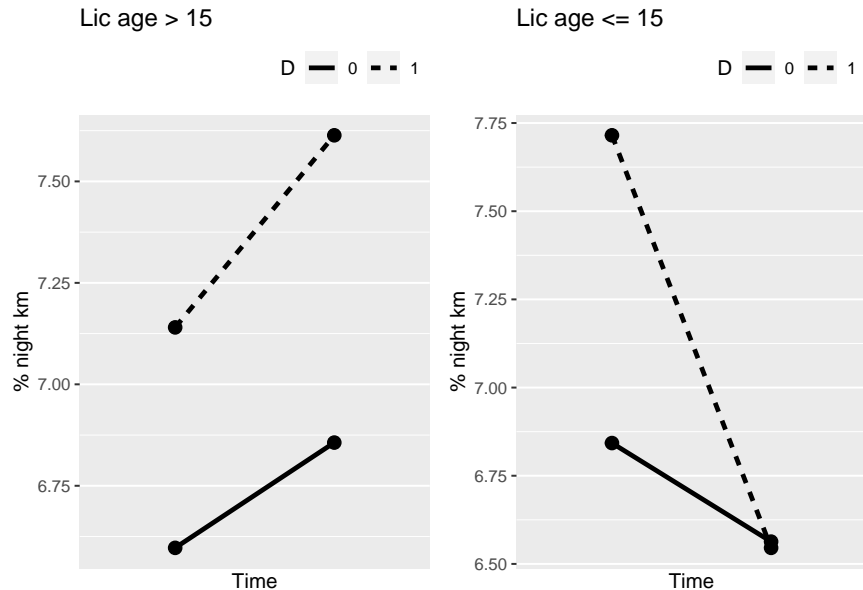
A més a més, a continuació es mirarà què passaria si traièssim de l'últim model realitzat la variable **parking_yes** en ser aquesta una variable que sabem que no és gaire rellevant per a la nostra variable dependent i que podria afectar a que altres variables importants no surtissin significatives. Com es pot notar, en aquest cas **lic_age15** ha passat a ser significativa mentre **power100** ho ha deixat de ser. A l'analitzar la gràfica notem que tots els individus amb menys de 15 anys de llicència han reduït el percentatge de quilòmetres conduïts durant la nit, mentre el comportament ha estat contrari pels usuaris amb més de 15 anys de carnet. A més a més, mentre la diferència en percentatge ha reduït del pre al post tractament pels usuaris amb menys de 15 anys de llicència, aquesta ha augmentat per la resta d'assegurats. No obstant això, l'AIC del model ha augmentat i l' R^2_{Adj} ha disminuït respecte a l'últim model creat, indicant que el prèvi és millor, com esperat perquè sinó la funció stepAIC ja hauria eliminat la variable **parking_yes** ella mateixa.

Table 31: TWFE for Night variable with reduced covariates without parking_yes

	Estimate	Std. Error	t value	Pr(> t)	R2	R2Adj	AIC
Tr	-0.3008	0.4865	-0.6182	0.5364	0.5617	0.122	73055.49
age35	1.5955	0.3291	4.8480	0.0000	0.5617	0.122	73055.49
age35_2	-1.2442	0.2568	-4.8449	0.0000	0.5617	0.122	73055.49
woman	-2.7344	0.2544	-10.7466	0.0000	0.5617	0.122	73055.49
woman_2	0.8200	0.1991	4.1184	0.0000	0.5617	0.122	73055.49
BMzones_2	0.7732	0.2577	3.0007	0.0027	0.5617	0.122	73055.49
power100_2	-0.7944	0.1957	-4.0588	0.0000	0.5617	0.122	73055.49
lic_age15_2_Tr	-2.0905	0.7616	-2.7448	0.0061	0.5617	0.122	73055.49
power100_2_Tr	1.2828	0.6260	2.0492	0.0405	0.5617	0.122	73055.49

Table 32: Some effects

	lic_age15	power100
coef	-2.3913	0.1877
Z	-3.0147	0.4185
p_value	0.0013	0.3378



A més a més, ens podríem plantejar el fet que l'edat i els anys de llicència són variables que aporten informació massa similar en quan a l'actitud o característiques de la persona i que per tant només 1 d'elles s'hauria de quedar en el model. Ja que de fet, en l'últim model provat han sortit com a significatives les variables que parlen sobre l'edat per elles mateixes, mentre eren els anys de llicència els que es trobaven relacionats amb Tr. En aquest cas, els resultats dels models amb i sense la variable pàrquing i quedant-nos amb la variable age35 o lic_age15 són els que es poden trobar a continuació.

Les observacions més rellevants extretes d'aquests models són que introduir la variable **parking_yes** en el model dona lloc a que l' ATT_2 de la variable **power100** sigui significatiu (o quasi significatiu pel cas en que va acompanyat de la variable anys de llicència) i positiu, mentre l'efecte del tractament tant de l'edat com dels anys de llicència són no significatius. Altrament, al treure la variable **parking_yes**, és la variable **power100** la que passa a tenir un efecte del tractament no significatiu, mentre **age35** i **lic_age15** donen lloc a un ATT_2 significatiu i negatiu.

També es conclou que si només es pogués disposar d'una de les dues variables per a predir el percentatge de quilòmetres nocturns que recorren els assegurats, es preferiria disposar de la variable edat en resultar els seus models en un AIC menor.

Table 33: TWFE for Night variable with reduced covariates without lic_age15

	Estimate	Std. Error	t value	Pr(> t)	R2	R2Adj	AIC
Tr	0.6760	0.6598	1.0246	0.3055	0.5619	0.1221	73047.39
age35	1.5804	0.3290	4.8035	0.0000	0.5619	0.1221	73047.39
age35_2	-1.1467	0.2659	-4.3126	0.0000	0.5619	0.1221	73047.39
parking_yes	1.0296	0.3134	3.2850	0.0010	0.5619	0.1221	73047.39
woman	-2.7277	0.2543	-10.7249	0.0000	0.5619	0.1221	73047.39
woman_2	0.8200	0.1990	4.1201	0.0000	0.5619	0.1221	73047.39
BMzones_2	0.7570	0.2575	2.9393	0.0033	0.5619	0.1221	73047.39
power100_2	-0.7787	0.1958	-3.9775	0.0001	0.5619	0.1221	73047.39
age35_2_Tr	-1.6706	0.8358	-1.9987	0.0457	0.5619	0.1221	73047.39
parking_yes2_Tr	-1.4872	0.6391	-2.3270	0.0200	0.5619	0.1221	73047.39
power100_2_Tr	1.1408	0.6258	1.8230	0.0683	0.5619	0.1221	73047.39

Table 34: Some effects

	age35	parking_yes	power100
coef	-0.5608	0.2185	1.0382
Z	-0.5649	0.3624	1.7136
p_value	0.2861	0.3585	0.0433

Table 35: TWFE for Night variable with reduced covariates without lic_age15 and parking_yes

	Estimate	Std. Error	t value	Pr(> t)	R2	R2Adj	AIC
Tr	-0.3622	0.4878	-0.7425	0.4578	0.5616	0.1218	73058.33
age35	1.5773	0.3291	4.7922	0.0000	0.5616	0.1218	73058.33
age35_2	-1.1485	0.2660	-4.3174	0.0000	0.5616	0.1218	73058.33
woman	-2.7297	0.2545	-10.7271	0.0000	0.5616	0.1218	73058.33
woman_2	0.8179	0.1991	4.1077	0.0000	0.5616	0.1218	73058.33
BMzones_2	0.7656	0.2577	2.9712	0.0030	0.5616	0.1218	73058.33

	Estimate	Std. Error	t value	Pr(> t)	R2	R2Adj	AIC
power100_2	-0.7985	0.1958	-4.0790	0.0000	0.5616	0.1218	73058.33
age35_2_Tr	-1.8060	0.8342	-2.1649	0.0304	0.5616	0.1218	73058.33
power100_2_Tr	1.2242	0.6253	1.9576	0.0503	0.5616	0.1218	73058.33

Table 36: Some effects

	age35	power100
coef	-1.7394	0.0635
Z	-2.0280	0.1432
p_value	0.0213	0.4431

Table 37: TWFE for Night variable with reduced covariates without age35

	Estimate	Std. Error	t value	Pr(> t)	R2	R2Adj	AIC
Tr	0.4715	0.6751	0.6985	0.4849	0.5613	0.1208	73073.29
lic_age15	0.6295	0.3043	2.0684	0.0386	0.5613	0.1208	73073.29
lic_age15_2	-0.4081	0.2562	-1.5927	0.1113	0.5613	0.1208	73073.29
parking_yes	1.1490	0.3259	3.5254	0.0004	0.5613	0.1208	73073.29
parking_yes2	-0.3108	0.2152	-1.4441	0.1487	0.5613	0.1208	73073.29
woman	-2.7647	0.2549	-10.8483	0.0000	0.5613	0.1208	73073.29
woman_2	0.8541	0.1996	4.2780	0.0000	0.5613	0.1208	73073.29
BMzones_2	0.7309	0.2589	2.8225	0.0048	0.5613	0.1208	73073.29
power100_2	-0.8190	0.1979	-4.1376	0.0000	0.5613	0.1208	73073.29
lic_age15_2_Tr	-1.8734	0.7981	-2.3473	0.0189	0.5613	0.1208	73073.29
parking_yes2_Tr	-1.1731	0.6714	-1.7472	0.0806	0.5613	0.1208	73073.29
power100_2_Tr	1.2433	0.6279	1.9799	0.0477	0.5613	0.1208	73073.29

Table 38: Some effects

	lic_age15	parking_yes	power100
coef	-1.1805	0.1367	0.8958
Z	-1.2056	0.2247	1.4307
p_value	0.1140	0.4111	0.0763

Table 39: TWFE for Night variable with reduced covariates without age35 and parking_yes

	Estimate	Std. Error	t value	Pr(> t)	R2	R2Adj	AIC
Tr	-0.3080	0.4882	-0.6308	0.5282	0.5612	0.1208	73083.5
lic_age15	0.6372	0.3043	2.0940	0.0363	0.5612	0.1208	73083.5
lic_age15_2	-0.4431	0.2553	-1.7357	0.0826	0.5612	0.1208	73083.5
woman	-2.7571	0.2550	-10.8110	0.0000	0.5612	0.1208	73083.5
woman_2	0.8375	0.1997	4.1945	0.0000	0.5612	0.1208	73083.5
BMzones	-0.8904	0.5728	-1.5545	0.1201	0.5612	0.1208	73083.5

	Estimate	Std. Error	t value	Pr(> t)	R2	R2Adj	AIC
BMzones_2	0.8533	0.2644	3.2273	0.0013	0.5612	0.1208	73083.5
power100_2	-0.8031	0.1966	-4.0857	0.0000	0.5612	0.1208	73083.5
lic_age15_2_Tr	-2.0786	0.7942	-2.6171	0.0089	0.5612	0.1208	73083.5
power100_2_Tr	1.3084	0.6270	2.0868	0.0369	0.5612	0.1208	73083.5

Table 40: Some effects

	lic_age15	power100
coef	-2.1925	0.1973
Z	-2.6823	0.4382
p_value	0.0037	0.3306

3.2.1.3 Variable Speed amb l'efecte de covariables Per a la variable dependent **Speed** s'observa un efecte del tractament negatiu però no significatiu. El signe es troba en consonància amb allò esperat, ja que aquells usuaris que han tingut un accident, s'espera que conduixin més lentament posteriorment a l'accident. Tanmateix, com comentat el pvalor d'aquest coeficient no és estadísticament significatiu, raó per la qual no es pot concloure res mirant aquests resultats.

Pel que fa als usuaris que tenen menys de 35 anys, aquests tenen un coeficient positiu i significatiu, indicant que conduïxen a major velocitat que els usuaris de major edat. De fet, aquest coeficient passa a ser positiu gràcies a la variable **age35_2**. Això indica que a $t=1$ els usuaris joves sí que conduïxen més lent, però a $t=2$ guanyen més confiança. A més a més, el coeficient dels usuaris que tenen el carnet des de fa menys de 15 anys és negatiu. Es pot concloure doncs que els joves són irresponsables al conduir ràpidament, però que sí que es mantenen amb major percentatge dins dels límits de velocitat, si fa poc que s'han tret el carnet.

Tal com esperat, les dones trenquen menys els límits de velocitat, així com aquells usuaris que tenen cotxes petits. Conduir per Madrid o Barcelona també mostra un signe negatiu, segurament degut a la major presència de radars en aquestes ciutats. Si s'analitzen les interaccions que han sortit significatives es pot notar que tot i que aquestes milloren el model, totes elles mostren un ATT_2 no significatiu. Això indica que tenir un accident no impacta de cap manera significativa sobre la velocitat de conducció dels usuaris, independentment de les seves característiques. Tot i així, sí que cal recalcar el fet que han tornat a sortir les mateixes interaccions que sortien per a la variable dependent **Night**, (prenent **age35** i **lic_age15** com a variable similars, indicadors del temps). Això indica clarament quines són les covariables més rellevants.

Table 41: TWFE for Speed variable with covariates

	Estimate	Std. Error	t value	Pr(> t)	R2	R2Adj	AIC
Tr	-0.1377	0.6206	-0.2218	0.8245	0.7281	0.4544	69550.86
age35	-0.7480	0.3034	-2.4654	0.0137	0.7281	0.4544	69550.86
age35_2	1.2145	0.2517	4.8252	0.0000	0.7281	0.4544	69550.86
lic_age15	-2.4838	0.2809	-8.8416	0.0000	0.7281	0.4544	69550.86
lic_age15_2	1.0852	0.2420	4.4848	0.0000	0.7281	0.4544	69550.86
parking_yes	0.5479	0.2833	1.9337	0.0532	0.7281	0.4544	69550.86
parking_yes2	0.0885	0.1863	0.4750	0.6348	0.7281	0.4544	69550.86
woman	-0.8794	0.2273	-3.8683	0.0001	0.7281	0.4544	69550.86
woman_2	0.0505	0.1806	0.2798	0.7796	0.7281	0.4544	69550.86
BMzones	-2.2175	0.4972	-4.4598	0.0000	0.7281	0.4544	69550.86
BMzones_2	0.7890	0.2399	3.2888	0.0010	0.7281	0.4544	69550.86
power100	-2.8949	0.2388	-12.1232	0.0000	0.7281	0.4544	69550.86
power100_2	0.8483	0.1839	4.6121	0.0000	0.7281	0.4544	69550.86

	Estimate	Std. Error	t value	Pr(> t)	R2	R2Adj	AIC
age35_2_Tr	-1.7088	0.7726	-2.2117	0.0270	0.7281	0.4544	69550.86
lic_age15_2_Tr	1.0418	0.7377	1.4124	0.1579	0.7281	0.4544	69550.86
parking_yes2_Tr	-1.1890	0.5813	-2.0453	0.0408	0.7281	0.4544	69550.86
woman_2_Tr	0.5833	0.5556	1.0498	0.2939	0.7281	0.4544	69550.86
BMzones_2_Tr	-0.8570	0.7530	-1.1381	0.2551	0.7281	0.4544	69550.86
power100_2_Tr	1.1748	0.5608	2.0948	0.0362	0.7281	0.4544	69550.86

Table 42: TWFE for Speed variable with reduced covariates

	Estimate	Std. Error	t value	Pr(> t)	R2	R2Adj	AIC
Tr	-0.1068	0.5710	-0.1871	0.8516	0.7279	0.4545	69545.53
age35	-0.7367	0.3033	-2.4291	0.0151	0.7279	0.4545	69545.53
age35_2	1.1748	0.2496	4.7068	0.0000	0.7279	0.4545	69545.53
lic_age15	-2.4838	0.2806	-8.8507	0.0000	0.7279	0.4545	69545.53
lic_age15_2	1.1915	0.2316	5.1455	0.0000	0.7279	0.4545	69545.53
parking_yes	0.5672	0.2728	2.0795	0.0376	0.7279	0.4545	69545.53
woman	-0.8306	0.2102	-3.9515	0.0001	0.7279	0.4545	69545.53
BMzones	-2.2581	0.4960	-4.5523	0.0000	0.7279	0.4545	69545.53
BMzones_2	0.7104	0.2281	3.1148	0.0018	0.7279	0.4545	69545.53
power100	-2.9048	0.2378	-12.2176	0.0000	0.7279	0.4545	69545.53
power100_2	0.8439	0.1771	4.7658	0.0000	0.7279	0.4545	69545.53
age35_2_Tr	-1.3522	0.7237	-1.8684	0.0617	0.7279	0.4545	69545.53
parking_yes2_Tr	-1.0175	0.5533	-1.8390	0.0659	0.7279	0.4545	69545.53
power100_2_Tr	1.4009	0.5417	2.5863	0.0097	0.7279	0.4545	69545.53

Table 43: Some effects

	age<=35	parking_yes	power<=100
coef	-1.0209	-0.5571	-0.7669
Z	-1.1794	-1.0664	-1.3941
p_value	0.1191	0.1431	0.0816

Tot seguit, es decideix mirar altre cop què passaria si s'eliminès de l'últim model realitzat la variable **parking_yes** en ser aquesta una variable que no hauria de ser gaire rellevant per a la variable dependent estudiada i que podria afectar a que altres variables importants no surtissin significatives.

Com podem notar, aquest simple canvi de treure la variable **parking_yes** ha provocat que ara tant **age35** com **power100** mostrin ATT_2 significatius, tot i que l'AIC augmenti de forma lleugera. Amb les gràfiques es pot notar clarament que els usuaris que han canviat més el seu comportament després de patir accidents són aquells que condueixen cotxes grans i que tenen menys de 35 anys.

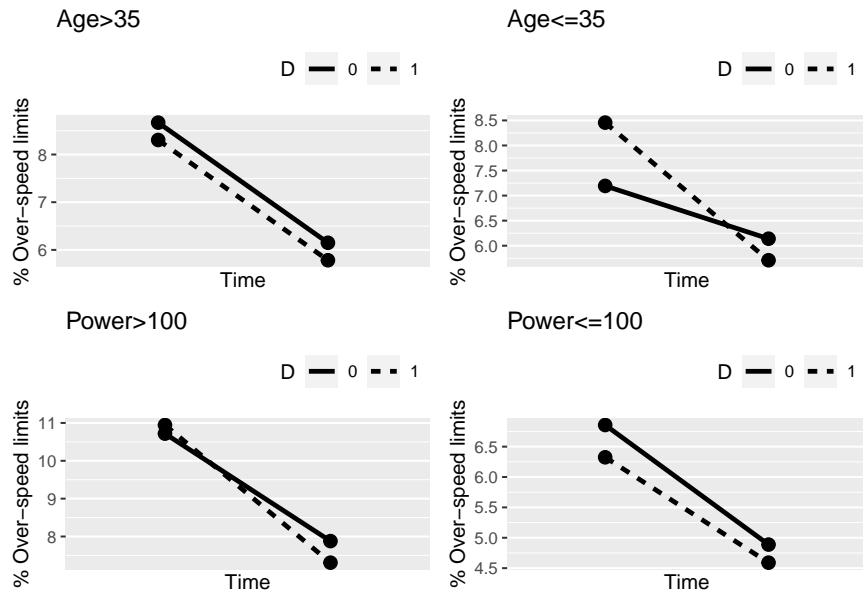
Table 44: TWFE for Speed variable with reduced covariates without parking_yes

	Estimate	Std. Error	t value	Pr(> t)	R2	R2Adj	AIC
Tr	-0.8155	0.4220	-1.9322	0.0534	0.7277	0.4544	69548.61
age35	-0.7306	0.3033	-2.4084	0.0160	0.7277	0.4544	69548.61
age35_2	1.1763	0.2496	4.7120	0.0000	0.7277	0.4544	69548.61

	Estimate	Std. Error	t value	Pr(> t)	R2	R2Adj	AIC
lic_age15	-2.4930	0.2806	-8.8857	0.0000	0.7277	0.4544	69548.61
lic_age15_2	1.1827	0.2315	5.1085	0.0000	0.7277	0.4544	69548.61
woman	-0.8228	0.2102	-3.9144	0.0001	0.7277	0.4544	69548.61
BMzones	-2.3050	0.4956	-4.6507	0.0000	0.7277	0.4544	69548.61
BMzones_2	0.7207	0.2281	3.1595	0.0016	0.7277	0.4544	69548.61
power100	-2.9462	0.2369	-12.4358	0.0000	0.7277	0.4544	69548.61
power100_2	0.8442	0.1771	4.7669	0.0000	0.7277	0.4544	69548.61
age35_2_Tr	-1.4464	0.7220	-2.0033	0.0452	0.7277	0.4544	69548.61
power100_2_Tr	1.4573	0.5411	2.6934	0.0071	0.7277	0.4544	69548.61

Table 45: Some effects

	age35	power100
coef	-1.8162	-1.4601
Z	-2.4211	-3.5010
p_value	0.0077	0.0002



A més a més, tal com fet fins ara, es mirarà què passaria si es considerès dins del model només la variable edat o només els anys de llicència, en poder presentar aquestes dues variables multicolinealitat i no deixar entreveure altres resultats.

En aquest cas les conclusions extremes d'aquestes combinacions de models són molt diferents respecte a les que s'han obtingut anteriorment amb la variable **Night**. Concretament, considerar la variable anys de llicència per al percentatge de quilòmetres recorreguts per sobre de la velocitat permesa no ajuda en no sortir aquesta interacció com a significativa en cap cas. D'altra banda, si s'introdueix la variable edat aquesta sempre surt significativa i amb un efecte del tractament negatiu, coincidint el signe en aquest cas sí amb els resultats que s'obtenien per **Night**. Finalment, la variable **power100** ha sortit significativa (o quasi significativa) amb un signe negatiu, a diferència del que s'obtenia per **Night**.

Això ens dur a concloure que l'edat de la persona és molt més rellevant que els anys de llicència d'aquesta pel que fa a predir la velocitat en funció de si l'usuari ha tingut un accident o no. A més a més, sabem

que els usuaris amb menys de 35 anys que pateixen un accident redueixen la velocitat després de tenir-lo, així com aquells que tenen cotxes amb baixa potència. Aquesta última afirmació era contrària pel cas del percentatge de quilòmetres recorreguts nocturnament, en mostrar la variable **power100** un signe positiu de l'efecte del tractament, indicant doncs que les persones amb cotxes de baixa potència augmenten la diferència de quilòmetres recorreguts nocturnament de forma positiva, respecte als usuaris que no n'han tingut cap.

No obstant això, cal tenir en compte que l' R^2_{Adj} és major per al model que elimina la variable edat i manté **lic_age15**. Així doncs, mentre si es vol analitzar què succeix després d'un accident disposar de la variable edat és millor. Si es vol predir amb major precisió el percentatge de quilòmetres per sobre de la velocitat dels assegurats, disposar dels anys de llicència és millor.

Table 46: TWFE for Speed variable with reduced covariates without **lic_age15**

	Estimate	Std. Error	t value	Pr(> t)	R2	R2Adj	AIC
Tr	-0.1099	0.5728	-0.1919	0.8478	0.7266	0.452	69622.99
age35	-1.6354	0.2868	-5.7026	0.0000	0.7266	0.452	69622.99
age35_2	1.6197	0.2309	7.0133	0.0000	0.7266	0.452	69622.99
parking_yes	0.6295	0.2736	2.3013	0.0214	0.7266	0.452	69622.99
woman	-0.8531	0.2108	-4.0477	0.0001	0.7266	0.452	69622.99
BMzones	-2.4923	0.4970	-5.0148	0.0000	0.7266	0.452	69622.99
BMzones_2	0.8154	0.2283	3.5721	0.0004	0.7266	0.452	69622.99
power100	-3.0884	0.2377	-12.9950	0.0000	0.7266	0.452	69622.99
power100_2	0.9401	0.1767	5.3194	0.0000	0.7266	0.452	69622.99
age35_2_Tr	-1.4631	0.7258	-2.0157	0.0439	0.7266	0.452	69622.99
parking_yes2_Tr	-0.9337	0.5549	-1.6826	0.0925	0.7266	0.452	69622.99
power100_2_Tr	1.3864	0.5434	2.5514	0.0107	0.7266	0.452	69622.99

Table 47: Some effects

	age35	parking_yes	power100
coef	-1.5887	-0.4140	-0.8717
Z	-1.8430	-0.7903	-1.5799
p_value	0.0327	0.2147	0.0571

Table 48: TWFE for Speed variable with reduced covariates without **lic_age15** and **parking_yes**

	Estimate	Std. Error	t value	Pr(> t)	R2	R2Adj	AIC
Tr	-0.7605	0.4234	-1.7961	0.0725	0.7264	0.4519	69626.48
age35	-1.6334	0.2868	-5.6946	0.0000	0.7264	0.4519	69626.48
age35_2	1.6173	0.2310	7.0014	0.0000	0.7264	0.4519	69626.48
woman	-0.8449	0.2108	-4.0085	0.0001	0.7264	0.4519	69626.48
BMzones	-2.5452	0.4965	-5.1258	0.0000	0.7264	0.4519	69626.48
BMzones_2	0.8261	0.2283	3.6188	0.0003	0.7264	0.4519	69626.48
power100	-3.1352	0.2368	-13.2416	0.0000	0.7264	0.4519	69626.48
power100_2	0.9400	0.1768	5.3172	0.0000	0.7264	0.4519	69626.48
age35_2_Tr	-1.5492	0.7242	-2.1392	0.0324	0.7264	0.4519	69626.48
power100_2_Tr	1.4399	0.5428	2.6526	0.0080	0.7264	0.4519	69626.48

Table 49: Some effects

	age35	power100
coef	-2.3258	-1.5158
Z	-3.1236	-3.6240
p_value	0.0009	0.0001

Table 50: TWFE for Speed variable with reduced covariates without age35

	Estimate	Std. Error	t value	Pr(> t)	R2	R2Adj	AIC
Tr	-0.2780	0.5653	-0.4918	0.6229	0.7272	0.4533	69562.7
lic_age15	-2.7122	0.2647	-10.2464	0.0000	0.7272	0.4533	69562.7
lic_age15_2	1.5956	0.2130	7.4918	0.0000	0.7272	0.4533	69562.7
parking_yes	0.5647	0.2730	2.0688	0.0386	0.7272	0.4533	69562.7
woman	-0.8236	0.2103	-3.9168	0.0001	0.7272	0.4533	69562.7
BMzones	-2.2234	0.4959	-4.4841	0.0000	0.7272	0.4533	69562.7
BMzones_2	0.7091	0.2283	3.1065	0.0019	0.7272	0.4533	69562.7
power100	-2.9168	0.2376	-12.2753	0.0000	0.7272	0.4533	69562.7
power100_2	0.8591	0.1772	4.8486	0.0000	0.7272	0.4533	69562.7
parking_yes2_Tr	-1.0594	0.5523	-1.9180	0.0551	0.7272	0.4533	69562.7
power100_2_Tr	1.3564	0.5418	2.5034	0.0123	0.7272	0.4533	69562.7

Table 51: Some effects

	parking_yes	power100
coef	-0.7726	-0.9793
Z	-1.5186	-1.8062
p_value	0.0644	0.0354

Table 52: TWFE for Speed variable with reduced covariates without age35 and parking_yes

	Estimate	Std. Error	t value	Pr(> t)	R2	R2Adj	AIC
Tr	-1.0309	0.4076	-2.5290	0.0115	0.727	0.4532	69566
lic_age15	-2.7194	0.2646	-10.2765	0.0000	0.727	0.4532	69566
lic_age15_2	1.5843	0.2129	7.4416	0.0000	0.727	0.4532	69566
woman	-0.8160	0.2103	-3.8805	0.0001	0.727	0.4532	69566
BMzones	-2.2712	0.4954	-4.5842	0.0000	0.727	0.4532	69566
BMzones_2	0.7192	0.2283	3.1507	0.0016	0.727	0.4532	69566
power100	-2.9572	0.2368	-12.4896	0.0000	0.727	0.4532	69566
power100_2	0.8597	0.1772	4.8507	0.0000	0.727	0.4532	69566
power100_2_Tr	1.4129	0.5413	2.6101	0.0091	0.727	0.4532	69566

Table 53: Some effects

	power100
coef	-1.7156
Z	-4.2943
p_value	0.0000

3.2.1.4 Variable Urban amb l'efecte de covariables Tornem a trobar que algunes interaccions són significatives. D'altra banda, l'estimador de l'efecte del tractament és negatiu però no significatiu. Pel que fa a les variables sense interaccions podem veure que el fet de tenir menys de 35 anys implica conduir més per vies urbanes, així com tenir un cotxe petit, tot i que per tots dos factors aquest percentatge disminueix durant el període de post-tractament. Ser dona i conduir per Madrid o Barcelona implica conduir un percentatge menor per vies urbanes i finalment tenir la llicència fa menys de 15 anys, conduir-ne més per aquest tipus de via.

No obstant això, si considerem les interaccions incloses en el model entre **Tr** i les covariables, podem observar com l'estimador de l' ATT_2 associat amb **lic_age15** i **power100** són significatius al 1% i 0.3%, respectivament. A més a més, l'estimador associat amb les llicències joves és negatiu, volent dir que aquells usuaris que s'han tret el carnet fa poc, després de patir un accident preferixen conduir menys per vies urbanes, mentre els usuaris amb cotxes petits es troben més segurs conduint en aquestes condicions, en ser el seu estimador de signe positiu. Finalment pel que fa a les interaccions, comentar que tot i que la interacció entre la variable **woman** i **Tr** millora el model en quant a informació captada en relació a la quantitat d'informació considerada, al treure els estadístics particulars, aquesta és no significativa.

Amb les gràfiques d'aquelles interaccions que han sortit significatives es pot veure que les persones amb llicència des de fa més de 15 anys condueixen sistemàticament menys quilòmetres per vies urbanes. Així mateix, aquells que no han tingut cap accident en condueixen cada cop menys. Pel que fa als usuaris amb menys de 15 anys de carnet el comportament és a l'inversa, en ser els que han tingut un accident els que passen a fer menys quilòmetres per vies urbanes, tal com comentat anteriorment quan s'anализava el signe de l'efecte del tractament.

Pel que fa a la potència dels cotxes, s'observa que els usuaris que han tingut un accident condueixen sempre més per vies urbanes, independentment de si el seu cotxe és gran o petit, indicant que segurament molts d'aquests accidents hauran estat en aquestes vies. Així mateix en aquest cas són els usuaris amb cotxes petits qui condueixen més per aquest tipus de vies. Finalment es nota que tenir un accident dona lloc a fer menys quilòmetres per vies urbanes en el cas de cotxes grans, mentre l'efecte no és tant significatiu sobre els petits.

Table 54: TWFE for Urban variable with covariates

	Estimate	Std. Error	t value	Pr(> t)	R2	R2Adj	AIC
Tr	-1.7464	1.1674	-1.4960	0.1347	0.7427	0.4837	84878.47
age35	2.4984	0.5708	4.3774	0.0000	0.7427	0.4837	84878.47
age35_2	-1.1842	0.4735	-2.5010	0.0124	0.7427	0.4837	84878.47
lic_age15	1.8767	0.5285	3.5512	0.0004	0.7427	0.4837	84878.47
lic_age15_2	-0.0370	0.4552	-0.0813	0.9352	0.7427	0.4837	84878.47
parking_yes	-0.5348	0.5330	-1.0035	0.3157	0.7427	0.4837	84878.47
parking_yes2	0.3235	0.3505	0.9231	0.3560	0.7427	0.4837	84878.47
woman	-0.1805	0.4277	-0.4221	0.6730	0.7427	0.4837	84878.47
woman_2	-0.3900	0.3397	-1.1481	0.2510	0.7427	0.4837	84878.47
BMzones	-2.3852	0.9354	-2.5500	0.0108	0.7427	0.4837	84878.47
BMzones_2	-0.6111	0.4513	-1.3540	0.1758	0.7427	0.4837	84878.47
power100	2.1348	0.4492	4.7524	0.0000	0.7427	0.4837	84878.47
power100_2	-0.5670	0.3460	-1.6386	0.1013	0.7427	0.4837	84878.47


	Estimate	Std. Error	t value	Pr(> t)	R2	R2Adj	AIC
age35_2_Tr	-1.8221	1.4534	-1.2537	0.2100	0.7427	0.4837	84878.47
lic_age15_2_Tr	-2.8606	1.3877	-2.0615	0.0393	0.7427	0.4837	84878.47
parking_yes2_Tr	0.3418	1.0936	0.3126	0.7546	0.7427	0.4837	84878.47
woman_2_Tr	2.3575	1.0453	2.2554	0.0241	0.7427	0.4837	84878.47
BMzones_2_Tr	0.7338	1.4166	0.5180	0.6045	0.7427	0.4837	84878.47
power100_2_Tr	2.7862	1.0550	2.6410	0.0083	0.7427	0.4837	84878.47

Table 55: TWFE for Urban variable with reduced covariates

	Estimate	Std. Error	t value	Pr(> t)	R2	R2Adj	AIC
Tr	-1.6205	0.8621	-1.8797	0.0602	0.7426	0.4843	84868.04
age35	2.5052	0.5653	4.4318	0.0000	0.7426	0.4843	84868.04
age35_2	-1.3304	0.4179	-3.1834	0.0015	0.7426	0.4843	84868.04
lic_age15	1.8876	0.4889	3.8608	0.0001	0.7426	0.4843	84868.04
woman_2	-0.4615	0.3148	-1.4657	0.1428	0.7426	0.4843	84868.04
BMzones	-2.5892	0.9109	-2.8424	0.0045	0.7426	0.4843	84868.04
power100	2.1178	0.4334	4.8869	0.0000	0.7426	0.4843	84868.04
power100_2	-0.5751	0.3406	-1.6882	0.0914	0.7426	0.4843	84868.04
lic_age15_2_Tr	-3.3355	1.2498	-2.6689	0.0076	0.7426	0.4843	84868.04
woman_2_Tr	2.3824	1.0411	2.2883	0.0221	0.7426	0.4843	84868.04
power100_2_Tr	2.7532	1.0493	2.6237	0.0087	0.7426	0.4843	84868.04

Table 56: Some effects

	lic_age<=15	woman	power<=100
coef	-3.0684	0.3005	2.6754
Z	-2.2092	0.2877	2.7531
p_value	0.0136	0.3868	0.0030



Tal com fet amb la resta de models, es mirarà altre cop què passaria si només considerèssim la variable **age35** o **lic_age15**, però no totes dues a la vegada, en els models. En aquest cas no s'ha hagut de crear 4 models (considerant a més a més introduir o no la variable **parking_yes**), perquè aquesta era no significant en tots els cassos, indicant que no té res a veure amb la quantitat de conducció urbana que realitzen els ciutadans.

Les conclusions són que independentment de si es posa la variable edat o anys de llicència, totes dues mostren un efecte del tractament significatiu (o quasi pel cas d'**age35**) i negatiu, mentre la potència també surt en tot cas significativa i positiva, com passava en el cas de la variable **Night**.

A més a més, si s'analitzen els R^2_{Adj} o els AIC es pot notar que introduir els anys de llicència és més informatiu que introduir l'edat. Tot i així, el millor model continua sent el creat anteriorment, que considera totes dues informacions a la vegada.

Després d'haver analitzat tots els models d'aquesta secció i de tenir en compte els AIC's es pot concloure que posseir la variable edat és el millor si es vol predir el percentatge de quilòmetres que es recorreran de forma nocturna, mentre per a les altres 3 variables dependents aporta més informació els anys de carnet. Òbviament, en tots els cassos el millor és disposar de totes dues informacions.

Table 57: TWFE for Urban variable with reduced covariates without **lic_age15**

	Estimate	Std. Error	t value	Pr(> t)	R2	R2Adj	AIC
Tr	-1.5756	0.8566	-1.8394	0.0659	0.742	0.4831	84881.4
age35	3.1512	0.5378	5.8590	0.0000	0.742	0.4831	84881.4
age35_2	-1.1191	0.4332	-2.5833	0.0098	0.742	0.4831	84881.4
BMzones	-2.1447	0.9313	-2.3028	0.0213	0.742	0.4831	84881.4
BMzones_2	-0.6456	0.4283	-1.5073	0.1318	0.742	0.4831	84881.4
power100	2.2734	0.4320	5.2625	0.0000	0.742	0.4831	84881.4
power100_2	-0.7103	0.3316	-2.1423	0.0322	0.742	0.4831	84881.4
age35_2_Tr	-2.7783	1.3586	-2.0449	0.0409	0.742	0.4831	84881.4
woman_2_Tr	1.9275	0.9933	1.9405	0.0523	0.742	0.4831	84881.4
power100_2_Tr	2.7361	1.0461	2.6155	0.0089	0.742	0.4831	84881.4

Table 58: Some effects

	age35	woman	power100
coef	-2.3218	0.3519	2.7236
Z	-1.6121	0.3383	2.8324
p_value	0.0535	0.3676	0.0023

Table 59: TWFE for Urban variable with reduced covariates without **age35**

	Estimate	Std. Error	t value	Pr(> t)	R2	R2Adj	AIC
Tr	-1.6240	0.8627	-1.8826	0.0598	0.7423	0.4837	84886.4
lic_age15	2.4395	0.4597	5.3061	0.0000	0.7423	0.4837	84886.4
woman_2	-0.4705	0.3151	-1.4930	0.1355	0.7423	0.4837	84886.4
BMzones	-2.7573	0.9107	-3.0277	0.0025	0.7423	0.4837	84886.4
power100	2.2219	0.4332	5.1296	0.0000	0.7423	0.4837	84886.4
power100_2	-0.6344	0.3404	-1.8639	0.0624	0.7423	0.4837	84886.4
lic_age15_2_Tr	-3.6399	1.2463	-2.9205	0.0035	0.7423	0.4837	84886.4

	Estimate	Std. Error	t value	Pr(> t)	R2	R2Adj	AIC
woman_2_Tr	2.4324	1.0419	2.3345	0.0196	0.7423	0.4837	84886.4
power100_2_Tr	2.7945	1.0501	2.6612	0.0078	0.7423	0.4837	84886.4

Table 60: Some effects

	lic_age15	woman	power100
coef	-2.8245	0.3379	2.7579
Z	-2.0522	0.3233	2.8363
p_value	0.0201	0.3732	0.0023

3.2.2 Model semi-paramètric - Integració de propensity scores amb models Dif-in-Dif

L'estimador utilitza puntuacions de propensió per predir les probabilitats que cada observació estigui en cadascun dels quatre grups (control pre-tractament / control post-tractament / tractament pre-tractament / tractament post-tractament). Concretament, normalment s'utilitza algun tipus de regressió multinomial. L'efecte del tractament es calcula doncs com una mitjana ponderada dels resultats observats. Destacar també que en aquest cas per a calcular la variància de l'estimador i posteriorment poder fer inferència s'ha utilitzat el mètode delta. Així doncs, l'estimador de la variància en realitat és una aproximació.

Els resultats, a l'igual que per l'anterior mètode no paramètric donen en tot cas no significatius. Concretament, la variable **Total** sempre és la que mostra un pvalor més petit, mentre les altres tres variables dependents mostren pvalors molt propers a l'1 si es mira el resultat a 2 cues, interpretant doncs que no s'està captant absolutament cap informació rellevant de les dades. Com en tot cas, efectivament fer inferència a 1 cua fa reduir el pvalor a la meitat.

3.2.2.1 Variable Total amb l'efecte de covariables

Table 61: Propensity scores + DD for Total variable

	ATT_2	sd	z_stat	p_value	CI_lower	CI_upper
2-tails	795.6984	1925.327	0.4133	0.6794	-2977.873	4569.27
1-tail	795.6984	1925.327	0.4133	0.3397	-2371.183	Inf

3.2.2.2 Variable Night amb l'efecte de covariables

Table 62: Propensity scores + DD for Night variable

	ATT_2	sd	z_stat	p_value	CI_lower	CI_upper
2-tails	0.0388	3.3174	0.0117	0.9907	-6.4632	6.5408
1-tail	0.0388	3.3174	0.0117	0.4953	-5.4179	Inf

3.2.2.3 Variable Speed amb l'efecte de covariables

Table 63: Propensity scores + DD for Speed variable

	ATT_2	sd	z_stat	p_value	CI_lower	CI_upper
2-tails	-0.2023	3.2749	-0.0618	0.9507	-6.621	6.2163
1-tail	-0.2023	3.2749	-0.0618	0.4754	-Inf	5.1844

3.2.2.4 Variable Urban amb l'efecte de covariables

Table 64: Propensity scores + DD for Urban variable

	ATT_2	sd	z_stat	p_value	CI_lower	CI_upper
2-tails	0.5021	10.379	0.0484	0.9614	-19.8405	20.8446
1-tail	0.5021	10.379	0.0484	0.4807	-16.5699	Inf

3.3 Models amb covariables constants en el temps

A continuació, es vol dur a terme un anàlisi similar al fet anteriorment però considerant el conjunt de dades que té les variables constants en el temps.

3.3.1 Model TWFE

3.3.1.1 Variable Total amb l'efecte de covariables En primer lloc creem el model amb tots els efectes additius i multiplicatius de les covariables, així com la seva corresponent reducció feta manualment en estar treballant amb models de panells, els quals no permeten fer una optimització automàtica. Com es pot notar en aquest cas no se li introdueixen les variables sense el `_2*`.

Table 65: TWFE for Total variable with constant covariates

	Estimate	Std. Error	t-value	Pr(> t)	R2	R2Adj
Tr	807.3561	243.0341	3.3220	0.0009	0.5319	0.4049
lic_age15	-360.3023	218.4160	-1.6496	0.0991	0.5319	0.4049
parking_yes	975.3139	255.3572	3.8194	0.0001	0.5319	0.4049
parking_yes2	-706.2360	159.2244	-4.4355	0.0000	0.5319	0.4049
woman	-799.2458	199.7551	-4.0011	0.0001	0.5319	0.4049
woman_2	221.5632	151.6239	1.4613	0.1440	0.5319	0.4049

Table 66: TWFE for Total variable with covariates

	Estimate	Std. Error	t-value	Pr(> t)	R2	R2Adj
Tr	807.3561	243.0341	3.3220	0.0009	0.5319	0.4049
lic_age15	-360.3023	218.4160	-1.6496	0.0991	0.5319	0.4049
parking_yes	975.3139	255.3572	3.8194	0.0001	0.5319	0.4049
parking_yes2	-706.2360	159.2244	-4.4355	0.0000	0.5319	0.4049
woman	-799.2458	199.7551	-4.0011	0.0001	0.5319	0.4049
woman_2	221.5632	151.6239	1.4613	0.1440	0.5319	0.4049

Tanmateix, com fet anteriorment amb les dades que no eren constants en el temps, es decideix fer el model amb la funció `lm` per tal de poder optimitzar el resultat d'una forma més senzilla. Com fet anteriorment, primer s'han de centrar les variables al 0.

En aquest cas l'estimador de l'efecte del tractament és positiu i significatiu, havent augmentat el valor de l'estimador respecte al valor obtingut amb el dataset amb covariables no constants en el temps. També continuen sortint les mateixes variables com a importants excepte `lic_age15`, que ha desaparegut. Les que apareixen, ho fan amb la mateixa magnitud i signe.

Com a diferència rellevant, en aquest cas s'ha trobat 2 covariables amb interaccions significatives amb `Tr`. Tot i així, només la variable `woman` presenta un ATT_2 significatiu amb coeficient positiu. Amb l'ajuda del gràfic es pot concloure que els usuaris que han tingut un accident sempre condueixen més quilòmetres totals de mitja. Tanmateix, en el cas dels homes, haver-lo tingut implica disminuir menys la quantitat de condució que si no l'haguessin tingut respecte a les dones.

Table 67: TWFE for Total variable with cst covariates


	Estimate	Std. Error	t value	Pr(> t)	R2	R2Adj	AIC
Tr	1314.9408	457.4835	2.8743	0.0041	0.5669	0.1309	151918.6
age35_2	-155.5828	189.1700	-0.8224	0.4108	0.5669	0.1309	151918.6
lic_age15_2	299.2594	181.8971	1.6452	0.1000	0.5669	0.1309	151918.6
parking_yes2	-802.4975	133.7476	-6.0001	0.0000	0.5669	0.1309	151918.6
woman_2	222.0664	130.0064	1.7081	0.0877	0.5669	0.1309	151918.6
BMzones_2	283.2970	178.5069	1.5870	0.1125	0.5669	0.1309	151918.6
power100_2	-88.6118	133.3184	-0.6647	0.5063	0.5669	0.1309	151918.6
age35_2_Tr	-1185.3034	617.7485	-1.9187	0.0551	0.5669	0.1309	151918.6
lic_age15_2_Tr	-223.7309	614.4712	-0.3641	0.7158	0.5669	0.1309	151918.6
parking_yes2_Tr	-125.0706	442.3756	-0.2827	0.7774	0.5669	0.1309	151918.6
woman_2_Tr	-873.1574	440.4989	-1.9822	0.0475	0.5669	0.1309	151918.6
BMzones_2_Tr	807.3567	598.7511	1.3484	0.1776	0.5669	0.1309	151918.6
power100_2_Tr	324.4167	441.7583	0.7344	0.4627	0.5669	0.1309	151918.6

Table 68: TWFE for Total variable with cst reduced covariates

	Estimate	Std. Error	t value	Pr(> t)	R2	R2Adj	AIC
Tr	1480.5794	297.5773	4.9754	0.0000	0.5663	0.1311	151909.7
parking_yes2	-788.1425	125.7845	-6.2658	0.0000	0.5663	0.1311	151909.7
woman_2	215.9742	125.3211	1.7234	0.0849	0.5663	0.1311	151909.7
BMzones_2	371.8368	169.8095	2.1897	0.0286	0.5663	0.1311	151909.7
age35_2_Tr	-1311.6179	555.9548	-2.3592	0.0183	0.5663	0.1311	151909.7
woman_2_Tr	-787.1851	427.0280	-1.8434	0.0653	0.5663	0.1311	151909.7

Table 69: Some effects

	age35	woman
coef	168.9615	909.3685
Z	0.3092	2.7519
p_value	0.3786	0.0030



Tal com fet amb els models amb covariables canviants en el temps, es tornarà a analitzar com canvien aquests si s'introdueix únicament la variable `age35` o `lic_age15` dins d'aquests; així com també es mirarà com canvien al eliminar la variable `parking_yes` per complet si la seva interacció amb `Tr` surt significativa.

En aquest cas la interacció de `Tr` amb la variable `parking_yes` és no significativa i per tant no es considera treure-la del model. De fet, es nota que en aquest cas, considerant els estudis que es volen dur a terme, només s'ha d'estudiar si eliminar la variable `age35` del model dona lloc a que els anys de llicència "reemplacin" la informació en el model o no. A l'analitzar els resultats es pot notar que la informació és clarament no reemplaçada en no sortir el coeficient `lic_age15_2_Tr` com a significatiu. A més a més, l'AIC del model ha disminuït respecte l'anterior, tot i que l' R^2_{Adj} s'ha mantingut estable. La conclusió és clara: es necessita l'edat de l'assegurat per a predir amb major encert el nombre de quilòmetres totals que realitzarà un assegurat i els anys de llicència que tenen aquests conductors no aporta la mateixa informació. Fer notar que aquesta conclusió és contrària a la que s'obtenia quan s'analitzava el conjunt de dades amb covariables canviants en el temps. També es pot notar que eliminar l'edat fa que la interacció de la variable `woman` amb `Tr` sigui menys significativa que anteriorment, tot i que es continua trobant per sota del límit del 5%.

Table 70: TWFE for Total variable with cst reduced covariates without age35

	Estimate	Std. Error	t value	Pr(> t)	R2	R2Adj	AIC
Tr	1270.3442	284.0007	4.4730	0.0000	0.5661	0.1311	151913.3
parking_yes2	-799.1166	125.7337	-6.3556	0.0000	0.5661	0.1311	151913.3
woman_2	216.3443	125.3561	1.7258	0.0844	0.5661	0.1311	151913.3
BMzones_2	366.9327	169.8443	2.1604	0.0308	0.5661	0.1311	151913.3
woman_2_Tr	-780.5223	427.1384	-1.8273	0.0677	0.5661	0.1311	151913.3

Table 71: Some effects

	woman
coef	706.1661
Z	2.2129
p_value	0.0135

3.3.1.2 Variable Night amb l'efecte de covariables Així com passava en el cas del conjunt de dades amb les covariables canviants en el temps l'estimador de l'efecte del tractament és no significatiu i molt proper a 0. Tanmateix, en aquest cas només ha sortit 1 interacció amb la variable **Tr** com a rellevant. Al mostrar un efecte del tractament no significatiu, es conclou que cap de les covariables incloses en el conjunt de dades té un efecte rellevant en relació a si s'ha tingut un accident o no. Així doncs, els efectes anteriorment vistos a l'analitzar el conjunt de dades amb les covariables canviants en el temps sobre les variables **power100** i **lic_age15** han desaparegut.

Pel que fa a les variables sense interacció es pot notar que tenir menys de 35 anys, disposar de pàrquing i tenir un cotxe petit dona lloc a recórrer un percentatge de quilòmetres menor durant la nit durant el període de post-tractament. Contràriament, ser dona i conduir per Barcelona o Madrid, com a zones principals, augmenten aquest percentatge.

Table 72: TWFE for Night variable with cst covariates

	Estimate	Std. Error	t value	Pr(> t)	R2	R2Adj	AIC
Tr	0.1125	0.8103	0.1388	0.8896	0.5858	0.1689	48641.17
age35_2	-1.3587	0.3351	-4.0549	0.0001	0.5858	0.1689	48641.17
lic_age15_2	0.4530	0.3222	1.4060	0.1598	0.5858	0.1689	48641.17
parking_yes2	-0.4272	0.2369	-1.8032	0.0714	0.5858	0.1689	48641.17
woman_2	0.7643	0.2303	3.3189	0.0009	0.5858	0.1689	48641.17
BMzones_2	0.8543	0.3162	2.7019	0.0069	0.5858	0.1689	48641.17
power100_2	-0.7984	0.2361	-3.3810	0.0007	0.5858	0.1689	48641.17
age35_2_Tr	-0.5479	1.0942	-0.5007	0.6166	0.5858	0.1689	48641.17
lic_age15_2_Tr	-1.0566	1.0884	-0.9708	0.3317	0.5858	0.1689	48641.17
parking_yes2_Tr	-0.7938	0.7836	-1.0130	0.3111	0.5858	0.1689	48641.17
woman_2_Tr	0.8677	0.7803	1.1120	0.2661	0.5858	0.1689	48641.17
BMzones_2_Tr	-0.6225	1.0606	-0.5869	0.5573	0.5858	0.1689	48641.17
power100_2_Tr	1.0581	0.7825	1.3522	0.1764	0.5858	0.1689	48641.17

Table 73: TWFE for Night variable with cst reduced covariates

	Estimate	Std. Error	t value	Pr(> t)	R2	R2Adj	AIC
Tr	-0.4574	0.5605	-0.8161	0.4144	0.5856	0.1697	48635.25
age35_2	-1.2535	0.2927	-4.2828	0.0000	0.5856	0.1697	48635.25
parking_yes2	-0.4833	0.2248	-2.1493	0.0316	0.5856	0.1697	48635.25
woman_2	0.8613	0.2195	3.9230	0.0001	0.5856	0.1697	48635.25
BMzones_2	0.8177	0.3011	2.7152	0.0066	0.5856	0.1697	48635.25
power100_2	-0.7935	0.2344	-3.3851	0.0007	0.5856	0.1697	48635.25
power100_2_Tr	1.2558	0.7553	1.6625	0.0964	0.5856	0.1697	48635.25

Table 74: Some effects

power100	
coef	0.0048
Z	0.0093
p_value	0.4963

A diferència de amb les dades amb covariables canviants en el temps, la interacció amb **Tr** de la variable **parking_yes** no surt significativa i per tant només fa falta estudiar què passa quan deixem en el model

únicament `age35` o `lic_age15`. En aquest aspecte, el model altre cop es diferencia de la secció anterior, en mostrar únicament la variable `age35` com a important. Així doncs, podem mirar què passaria si únicament introduïm en el model `lic_age15`, tot i que ja sabem que els resultats empitjoraran. Es vol saber doncs si tot i no ser millor que `age35`, `lic_age15` pot ajudar a predir el percentatge de quilòmetres recorreguts nocturnament en absència de l'edat. La resposta és no, en no sortir la variable en el model creat. La significació de la interacció `power100-Tr` no canvia de forma rellevant.

Table 75: TWFE for Night variable with cst reduced covariates without age35

	Estimate	Std. Error	t value	Pr(> t)	R2	R2Adj	AIC
Tr	-0.5020	0.5610	-0.8948	0.3709	0.5849	0.1685	48651.58
parking_yes2	-0.5615	0.2243	-2.5029	0.0123	0.5849	0.1685	48651.58
woman_2	0.8644	0.2198	3.9329	0.0001	0.5849	0.1685	48651.58
BMzones_2	0.7763	0.3013	2.5765	0.0100	0.5849	0.1685	48651.58
power100_2	-0.8741	0.2339	-3.7370	0.0002	0.5849	0.1685	48651.58
power100_2_Tr	1.3244	0.7560	1.7520	0.0798	0.5849	0.1685	48651.58

Table 76: Some effects

	power100
coef	-0.0516
Z	-0.0996
p_value	0.4603

3.3.1.3 Variable Speed amb l'efecte de covariables Les conclusions més rellevants aquest cop són similars al model obtingut amb les covariables canviants en el temps. D'una banda, tots dos models han trobat varies interaccions dins del millor model escollit: `age35`, `lic_age15` i `power100`. Així mateix, en tots dos s'observa un efecte del tractament negatiu però no significatiu. A l'analitzar l'efecte a $t=2$ es nota que aquest és positiu i significatiu per a totes les variables, a diferència dels resultats que es trobaven anteriorment.

A l'analitzar les característiques per separat notem que totes les variables analitzades són significatives en quant a l'efecte del tractament. D'una banda l'edat presenta un ATT_2 negatiu indicant que aquells usuaris joves que tenen un accident, generalment decreixen la velocitat després de patir-lo. D'altra banda, els anys de llicència i la potència del cotxe presenten un valor positiu indicant que els usuaris que tenen cotxes petits i pocs anys de llicència, incrementen la velocitat després de tenir un accident, contràriament a l'esperat. Amb l'ajuda de les gràfiques podem veure que de fet, pel que fa als usuaris amb pocs anys de carnet, no és que aquells que tinguin un accident augmentin la seva velocitat, sinó que els que no el tenen la disminueixen encara més respecte al seu comportament anterior. Un comportament similar però menys marcat succeeix pels cotxes petits.

Table 77: TWFE for Speed variable with cst covariates

	Estimate	Std. Error	t value	Pr(> t)	R2	R2Adj	AIC
Tr	-0.6282	0.6748	-0.9309	0.3519	0.7708	0.5401	45657.81
age35_2	0.9046	0.2790	3.2419	0.0012	0.7708	0.5401	45657.81
lic_age15_2	1.2739	0.2683	4.7480	0.0000	0.7708	0.5401	45657.81
parking_yes2	-0.1447	0.1973	-0.7336	0.4632	0.7708	0.5401	45657.81
woman_2	-0.1912	0.1918	-0.9970	0.3188	0.7708	0.5401	45657.81
BMzones_2	0.8940	0.2633	3.3954	0.0007	0.7708	0.5401	45657.81
power100_2	0.9417	0.1967	4.7888	0.0000	0.7708	0.5401	45657.81

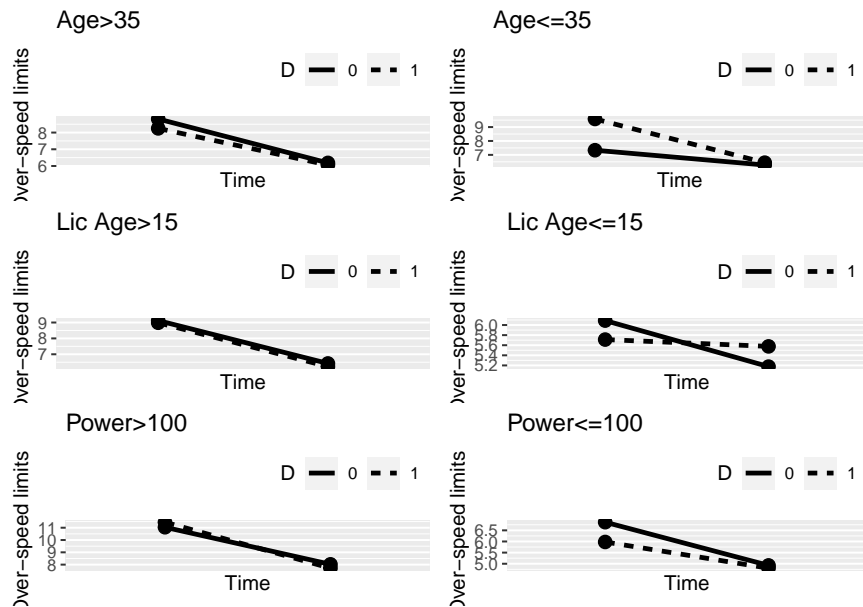
	Estimate	Std. Error	t value	Pr(> t)	R2	R2Adj	AIC
age35_2_Tr	-2.7658	0.9112	-3.0353	0.0024	0.7708	0.5401	45657.81
lic_age15_2_Tr	1.7177	0.9064	1.8952	0.0581	0.7708	0.5401	45657.81
parking_yes2_Tr	-0.2043	0.6525	-0.3131	0.7542	0.7708	0.5401	45657.81
woman_2_Tr	1.0097	0.6498	1.5540	0.1202	0.7708	0.5401	45657.81
BMzones_2_Tr	-0.8850	0.8832	-1.0020	0.3164	0.7708	0.5401	45657.81
power100_2_Tr	1.2600	0.6516	1.9337	0.0532	0.7708	0.5401	45657.81

Table 78: TWFE for Speed variable with cst reduced covariates

	Estimate	Std. Error	t value	Pr(> t)	R2	R2Adj	AIC
Tr	-0.5644	0.4898	-1.1522	0.2493	0.7702	0.5395	45652.28
age35_2	0.9056	0.2788	3.2486	0.0012	0.7702	0.5395	45652.28
lic_age15_2	1.2413	0.2665	4.6584	0.0000	0.7702	0.5395	45652.28
BMzones_2	0.8177	0.2505	3.2637	0.0011	0.7702	0.5395	45652.28
power100_2	0.9103	0.1890	4.8164	0.0000	0.7702	0.5395	45652.28
age35_2_Tr	-2.8461	0.9078	-3.1353	0.0017	0.7702	0.5395	45652.28
lic_age15_2_Tr	1.7032	0.9003	1.8919	0.0585	0.7702	0.5395	45652.28
power100_2_Tr	1.5360	0.6308	2.4348	0.0149	0.7702	0.5395	45652.28

Table 79: Some effects

	age<=35	lic_age<=15	power<=100
coef	-2.5049	2.3802	1.8820
Z	-2.7733	2.5666	4.0495
p_value	0.0028	0.0051	0.0000



Altre cop la variable `parking_yes` no surt en cap lloc del model i per tant no ens hem de preocupar per ella. No obstant això, en aquest cas sí que apareixen com a rellevants tant `age35` com `lic_age15`, inclús

presentant totes dues una interacció amb **Tr** en el model. Anteriorment s'ha vist que totes dues variable, així com **power100** presentaven un ATT_2 significatiu. A continuació es mirarà si la significació canvia a l'eliminar una de les dues variables de model. Eliminar els anys de llicència dona lloc a un pvalor de l' ATT_2 de la variable edat significatiu al 4.5%, mentre la significació de **power100** es continua mantenint intacte. D'altra banda, eliminar l'edat dona lloc a una eliminació completa de la interacció dels anys de llicència amb **Tr**, mentre altre cop els resultats de **power100** no canvien.

Tenint en compte el mencionat anteriorment i el fet que l'AIC del model sense **age35** és menor (i l' R^2_{Adj} major) en comparació al model sense **lic_age15**, s'hauria de concloure que si es vol analitzar com canvia el comportament d'un assegurat en front un accident seria millor disposar de la variable edat, mentre si es vol donar més importància a predir correctament el percentatge de quilòmetres que es durant a terme per sobre de la velocitat els anys de llicència d'un assegurat són més importants. Òbviament, en tot cas la millor opció seria disposar de totes dues variables, com en aquest treball.

Table 80: TWFE for Speed variable with cst reduced covariates without **lic_age15**

	Estimate	Std. Error	t value	Pr(> t)	R2	R2Adj	AIC
Tr	-0.4159	0.4854	-0.8569	0.3915	0.7687	0.5366	45681.64
age35_2	1.4369	0.2548	5.6391	0.0000	0.7687	0.5366	45681.64
BMzones_2	0.9040	0.2505	3.6088	0.0003	0.7687	0.5366	45681.64
power100_2	0.9952	0.1885	5.2796	0.0000	0.7687	0.5366	45681.64
age35_2_Tr	-2.4448	0.8597	-2.8438	0.0045	0.7687	0.5366	45681.64
power100_2_Tr	1.6132	0.6301	2.5602	0.0105	0.7687	0.5366	45681.64

Table 81: Some effects

	age35	power100
coef	-1.4239	2.1924
Z	-1.7012	4.8666
p_value	0.0445	0.0000

Table 82: TWFE for Speed variable with cst reduced covariates without **age35**

	Estimate	Std. Error	t value	Pr(> t)	R2	R2Adj	AIC
Tr	-0.7580	0.4668	-1.6238	0.1044	0.7706	0.5405	45662.63
lic_age15_2	1.6559	0.2333	7.0989	0.0000	0.7706	0.5405	45662.63
BMzones_2	0.8126	0.2507	3.2407	0.0012	0.7706	0.5405	45662.63
power100_2	0.9236	0.1890	4.8877	0.0000	0.7706	0.5405	45662.63
power100_2_Tr	1.5848	0.6293	2.5183	0.0118	0.7706	0.5405	45662.63

Table 83: Some effects

	power100
coef	1.7504
Z	4.0747
p_value	0.0000

3.3.1.4 Variable Urban amb l'efecte de covariables Tornem a trobar que algunes interaccions són significatives. D'altra banda, l'estimador de l'efecte del tractament és negatiu i significatiu, indicant que tenir un accident disminueix el percentatge de quilòmetres recorreguts per via urbana. Totes les variables que han sortit com a significatives mostren un efecte negatiu a $t=2$, indicant que tenir menys de 35 anys, tenir la llicència fa menys de 15 anys, conduir principalment per Barcelona o Madrid i tenir un cotxe petit fa disminuir el percentatge de quilòmetres recorreguts per vies urbanes.

Finalment, comentar que tot i que la interacció entre les variables **woman** i **lic_age15** i **Tr** milloren el model en quant a informació captada en relació a la quantitat d'informació considerada, al treure els estadístics particulars, els ATT_2 són no significatius.

Table 84: TWFE for Urban variable with cst covariates

	Estimate	Std. Error	t value	Pr(> t)	R2	R2Adj	AIC
Tr	-2.1855	1.1488	-1.9024	0.0571	0.8128	0.6243	54329.76
age35_2	-0.6695	0.4750	-1.4094	0.1587	0.8128	0.6243	54329.76
lic_age15_2	-1.3688	0.4568	-2.9969	0.0027	0.8128	0.6243	54329.76
parking_yes2	0.3585	0.3359	1.0676	0.2857	0.8128	0.6243	54329.76
woman_2	0.2167	0.3265	0.6639	0.5068	0.8128	0.6243	54329.76
BMzones_2	-1.0116	0.4482	-2.2567	0.0241	0.8128	0.6243	54329.76
power100_2	-0.6521	0.3348	-1.9480	0.0514	0.8128	0.6243	54329.76
age35_2_Tr	0.1554	1.5512	0.1002	0.9202	0.8128	0.6243	54329.76
lic_age15_2_Tr	2.6015	1.5430	1.6860	0.0918	0.8128	0.6243	54329.76
parking_yes2_Tr	0.1759	1.1108	0.1583	0.8742	0.8128	0.6243	54329.76
woman_2_Tr	2.4314	1.1061	2.1981	0.0280	0.8128	0.6243	54329.76
BMzones_2_Tr	-1.5878	1.5035	-1.0561	0.2910	0.8128	0.6243	54329.76
power100_2_Tr	0.8521	1.1093	0.7682	0.4424	0.8128	0.6243	54329.76

Table 85: TWFE for Urban variable with cst reduced covariates

	Estimate	Std. Error	t value	Pr(> t)	R2	R2Adj	AIC
Tr	-2.0101	0.7288	-2.7581	0.0058	0.8125	0.6244	54321.44
age35_2	-0.6494	0.4515	-1.4381	0.1504	0.8125	0.6244	54321.44
lic_age15_2	-1.3087	0.4498	-2.9093	0.0036	0.8125	0.6244	54321.44
BMzones_2	-1.1665	0.4264	-2.7355	0.0062	0.8125	0.6244	54321.44
power100_2	-0.5663	0.3077	-1.8406	0.0657	0.8125	0.6244	54321.44
lic_age15_2_Tr	2.6676	1.4465	1.8442	0.0652	0.8125	0.6244	54321.44
woman_2_Tr	2.7791	1.0289	2.7009	0.0069	0.8125	0.6244	54321.44

Table 86: Some effects

	lic_age<=15	woman
coef	-0.6511	0.7690
Z	-0.4700	0.9285
p_value	0.3192	0.1766

Altres cop la variable **parking_yes** no és en absolut rellevant en el model. No obstant això, la variable edat sí que ajuda a predir el percentatge de quilòmetres que els assegurats realitzaran per vies urbanes, mentre els anys de carnet, ajuden tant a l'anterior propòsit com a saber qui tindrà un accident amb major probabilitat, segons el model. Es realitzarà doncs altre cop el mateix procés que en la secció anterior. Destacar dels

resultats que deixar únicament la variable edat fa que l' ATT_2 de **woman** quasi bé sigui significatiu, indicant que **lic_age15** és un distractor per a aquesta variable, tot i que el model que conté **lic_age15** explica més informació que el que únicament conté **age35**.

La conclusió doncs és similar a la realitzada per a la variable **Speed** d'aquesta mateixa secció. Disposar de totes dues variables seria el millor. Tanmateix, si es vol analitzar com canvia el comportament d'un assegurat en front un accident seria millor disposar de la variable edat, mentre si es vol donar més importància a predir correctament el percentatge de quilòmetres que es durant a terme per sobre de la velocitat els anys de llicència d'un assegurat són més importants.

Així com pel cas del dataset amb covariables canviants en el temps s'ha conclòs que disposar dels anys de carnet era més informatiu (menor AIC) per a 3 de les 4 variables dependents, en aquest cas no es pot concloure res perquè l'edat és millor per a predir els quilòmetre totals que realitzaran els assegurats així com el percentatge de quilòmetres recorreguts durant la nit, mentre els anys de llicència són millor per a les altres dues variables "Urban" i "Speed". Així doncs, la variable "Total" és la única que ha canviat en aquest sentit al canviar de conjunt de dades.

Table 87: TWFE for Urban variable with cst reduced covariates without **lic_age15**

	Estimate	Std. Error	t value	Pr(> t)	R2	R2Adj	AIC
Tr	-1.5902	0.6971	-2.2810	0.0226	0.8116	0.6227	54327.12
age35_2	-1.1238	0.4136	-2.7170	0.0066	0.8116	0.6227	54327.12
BMzones_2	-1.2390	0.4257	-2.9102	0.0036	0.8116	0.6227	54327.12
power100_2	-0.6470	0.3064	-2.1114	0.0348	0.8116	0.6227	54327.12
woman_2_Tr	2.8462	1.0283	2.7680	0.0057	0.8116	0.6227	54327.12

Table 88: Some effects

	woman
coef	1.2560
Z	1.5974
p_value	0.0551

Table 89: TWFE for Urban variable with cst reduced covariates without **age35**

	Estimate	Std. Error	t value	Pr(> t)	R2	R2Adj	AIC
Tr	-2.0296	0.7287	-2.7851	0.0054	0.8126	0.6246	54321.51
lic_age15_2	-1.5630	0.4136	-3.7788	0.0002	0.8126	0.6246	54321.51
BMzones_2	-1.1668	0.4265	-2.7359	0.0062	0.8126	0.6246	54321.51
power100_2	-0.5782	0.3076	-1.8797	0.0602	0.8126	0.6246	54321.51
lic_age15_2_Tr	2.7186	1.4462	1.8799	0.0602	0.8126	0.6246	54321.51
woman_2_Tr	2.7924	1.0290	2.7138	0.0067	0.8126	0.6246	54321.51

Table 90: Some effects

	lic_age15	woman
coef	-0.8739	0.7629

	lic_age15	woman
Z	-0.6348	0.9210
p_value	0.2628	0.1785

3.3.2 Models semi-paramètrics (IWE)

A la pràctica l' \widehat{ATT}_2 que calcula aquest model, és la mitjana ponderada de cada conjunt de dades amb els mateixos valors per les covariables X_i . Són doncs bàsicament una mitjana mostral ponderada.

Només té sentit aplicar aquest tipus de models amb les solucions que en la secció anterior (TWFE amb covariables constants en el temps) han retornat interaccions dins del millor model seleccionat. Concretament, per a aplicar el mètode s'han de seleccionar els individus que compleixen les interaccions trobades com a rellevants. Amb rellevants ens referim a interaccions que han sortit en el model final, sense la necessitat que aquestes hagin hagut de ser significatives o que el seu efecte de tractament hagi resultat significatiu. Per a aquests usuaris s'ha d'aplicar el logit o altres mètodes com un tree o un random forest. S'ha de tenir en compte que a vegades ens podem quedar sense usuaris amb $Tr = 1$ al filtrar amb les variables d'interès (interaccions). En aquests cassos no s'hi pot fer res, simplement no es podrà aplicar el mètode, és precisament una de les debilitats d'aquest.

També s'ha de tenir en compte que a l'aplicar el mètode s'ha d'assumir que els períodes $t = 1$ i $t = 2$ són independents. Tanmateix, aquesta assumpció podria ser criticable perquè s'està tractant en tot cas amb els mateixos individus a $t = 1$ i $t = 2$, encara que existeixi 1 any pel mig.

A continuació es descriuran els resultats que s'obtenen en cada cas, tanmateix, la conclusió general és que els models (logit, tree i random forest) no donen lloc a cap resultat significatiu. De fet, si es realitzen els summary d'aquests es nota que tots els coeficients mostren pvalors no significatius. Altre cop, això és degut a que aquesta tipologia d'estimadors, els semi-paramètrics i els no paramètrics no serveixen per dades desbalancejades, com amb les que s'està tractant.

3.3.2.1 Variable Total amb l'efecte de covariables La variable `Total` ha mostrat en la secció anterior que tant l'edat com el fet de ser dona eren interaccions rellevants en el model 68. Així doncs, es filtrarà per totes dues. En primer lloc, es farà l'anàlisi per cadascuna d'elles de forma separada perquè es recorda que si es filtra massa, ens podem arribar a quedar sense representació.

Com a recordatori de la última secció cal comentar que la variable `age35` i `woman` havien sortit rellevants en el model, però només `woman` havia resultat en tenir un ATT_2 significatiu i positiu, mentre l'efecte del tractament del model era 1480, sent aquest significatiu. Tanmateix, en aquest cas cap de les combinacions de filtratges ha resultat en un efecte del tractament significatiu, sent la filtració per la variable `woman` la que s'ha trobat més aprop d'estar-ho.

3.3.2.1.1 Filtratge per “age35”

```
## Assegurats amb accidents que queden a la mostra: 56
```

```
## Millor ntree: 50
```

Table 91: IWE for Total variable filtering by age35

	ATT_2	sd	t_stat	p_value	CI_lower	CI_upper
Logit 2-tails	-28606.98	418185.9	-0.0684	0.9455	-849789.3	792575.3
Tree 2-tails	-108565.59	415732.7	-0.2611	0.7941	-924930.6	707799.5

	ATT_2	sd	t_stat	p_value	CI_lower	CI_upper
Random Forest 2-tails	-71539.46	418998.0	-0.1707	0.8645	-894316.5	751237.6
Logit 1-tail	-28606.98	418185.9	-0.0684	0.4727	-Inf	660244.8
Tree 1-tail	-108565.59	415732.7	-0.2611	0.3970	-Inf	576245.2
Random Forest 1-tail	-71539.46	418998.0	-0.1707	0.4322	-Inf	618650.0

3.3.2.1.2 Filtratge per “woman”

Assegurats amb accidents que queden a la mostra: 155

Millor ntree: 100

Table 92: IWE for Total variable filtering by woman

	ATT_2	sd	t_stat	p_value	CI_lower	CI_upper
Logit 2-tails	1019650.2	822555.3	1.2396	0.2153	-593500.3	2632801
Tree 2-tails	1057751.4	821880.8	1.2870	0.1982	-554076.5	2669579
Random Forest 2-tails	951941.9	823289.7	1.1563	0.2477	-662648.9	2566533
Logit 1-tail	1019650.2	822555.3	1.2396	0.1076	-333956.9	Inf
Tree 1-tail	1057751.4	821880.8	1.2870	0.0991	-294745.9	Inf
Random Forest 1-tail	951941.9	823289.7	1.1563	0.1239	-402873.8	Inf

3.3.2.1.3 Filtratge per “age35” i “woman”

Assegurats amb accidents que queden a la mostra: 24

Millor ntree: 50

Table 93: IWE for Total variable filtering by age35 and woman

	ATT_2	sd	t_stat	p_value	CI_lower	CI_upper
Logit 2-tails	286665.4	276699.3	1.0360	0.3010	-257651.5	830982.4
Tree 2-tails	306679.4	275576.4	1.1129	0.2666	-235428.6	848787.5
Random Forest 2-tails	288311.5	272962.4	1.0562	0.2916	-248654.2	825277.3
Logit 1-tail	286665.4	276699.3	1.0360	0.1505	-169745.6	Inf
Tree 1-tail	306679.4	275576.4	1.1129	0.1333	-147879.5	Inf
Random Forest 1-tail	288311.5	272962.4	1.0562	0.1458	-161935.5	Inf

3.3.2.2 Variable Night amb l’efecte de covariables Per a aquesta variable dependent els resultats obtinguts amb el model TWFE mostraven que l’ ATT_2 del model era no significatiu i molt proper a 0, mentre només 1 variable, **power100**, surtia com a rellevant en el model, mostrant aquesta un efecte del tractament no significatiu. Els resultats per a aquest nou model han canviat de forma significativa en obtenir un ATT_2 positiu i significatiu al filtrar per la variable **power100**.

3.3.2.2.1 Filtratge per “power100”

Assegurats amb accidents que queden a la mostra: 194

Millor ntrees: 150

Table 94: IWE for Night variable filtering by power100

	ATT_2	sd	t_stat	p_value	CI_lower	CI_upper
Logit 2-tails	2296911	905241.7	2.5373	0.0112	521768.6	4072053
Tree 2-tails	2286666	904378.4	2.5284	0.0115	513216.7	4060115
Random Forest 2-tails	2276111	905505.9	2.5136	0.0120	500451.1	4051771
Logit 1-tail	2296911	905241.7	2.5373	0.0056	807341.9	Inf
Tree 1-tail	2286666	904378.4	2.5284	0.0058	798517.7	Inf
Random Forest 1-tail	2276111	905505.9	2.5136	0.0060	786107.7	Inf

3.3.2.3 Variable Speed amb l’efecte de covariables En aquest cas el model TWFE amb variable constants en el temps ha deixat veure que l’efecte del tractament era no significatiu però que 3 de les seves variables sí que presentaven una interacció amb un ATT_2 significatiu: `age35`, `lic_age15` i `power100`. El primer efecte era negatiu mentre els dos segons positius. Amb els models IWE realitzats a continuació es pot notar que filtrar únicament per 1 variable dona lloc a obtenir pvalors més propers a ser significatius. Concretament, filtrar per la variable `lic_age15` és el que ha donat lloc a resultats més llunyants del 0.05%, seguit per `power100` i finalment `age35`, la qual de fet presenta un efecte del tractament significatiu i negatiu, com anteriorment. Aquest efecte és únicament significatiu amb els resultats obtinguts a 1 cua. De fet, en tots els cassos podem notar com la significació (pvalor) es divideix aproximadament per 2 en passar dels resultats de 2 cues a 1 cua. La última sentència afirma que és necessari treballar amb aquest tipus d’inferència.

3.3.2.3.1 Filtratge per “age35”

Assegurats amb accidents que queden a la mostra: 56

Millor ntrees: 50

Table 95: IWE for Speed variable filtering by age35

	ATT_2	sd	t_stat	p_value	CI_lower	CI_upper
Logit 2-tails	-1193.041	687.7481	-1.7347	0.0833	-2543.556	157.4745
Tree 2-tails	-1333.620	683.7136	-1.9506	0.0515	-2676.213	8.9727
Random Forest 2-tails	-1288.942	689.0837	-1.8705	0.0619	-2642.080	64.1959
Logit 1-tail	-1193.041	687.7481	-1.7347	0.0416	-Inf	-60.1562
Tree 1-tail	-1333.620	683.7136	-1.9506	0.0258	-Inf	-207.3813
Random Forest 1-tail	-1288.942	689.0837	-1.8705	0.0309	-Inf	-153.8574

3.3.2.3.2 Filtratge per “lic_age15”

Assegurats amb accidents que queden a la mostra: 57

Millor ntrees: 400

Table 96: IWE for Speed variable filtering by lic_age15

	ATT_2	sd	t_stat	p_value	CI_lower	CI_upper
Logit 2-tails	531.9211	656.0526	0.8108	0.4178	-756.0804	1819.923
Tree 2-tails	560.4917	653.7891	0.8573	0.3916	-723.0660	1844.049
Random Forest 2-tails	593.5365	656.3586	0.9043	0.3661	-695.0658	1882.139
Logit 1-tail	531.9211	656.0526	0.8108	0.2089	-548.5776	Inf
Tree 1-tail	560.4917	653.7891	0.8573	0.1958	-516.2792	Inf
Random Forest 1-tail	593.5365	656.3586	0.9043	0.1831	-487.4662	Inf

3.3.2.3.3 Filtratge per “power100”

Assegurats amb accidents que queden a la mostra: 194

Millor ntree: 150

Table 97: IWE for Speed variable filtering by power100

	ATT_2	sd	t_stat	p_value	CI_lower	CI_upper
Logit 2-tails	1871.395	1254.430	1.4918	0.1359	-588.4914	4331.281
Tree 2-tails	1821.932	1253.234	1.4538	0.1461	-635.6082	4279.472
Random Forest 2-tails	1884.082	1254.796	1.5015	0.1334	-576.5221	4344.686
Logit 1-tail	1871.395	1254.430	1.4918	0.0679	-192.7609	Inf
Tree 1-tail	1821.932	1253.234	1.4538	0.0731	-240.2551	Inf
Random Forest 1-tail	1884.082	1254.796	1.5015	0.0667	-180.6761	Inf

3.3.2.3.4 Filtratge per “age35” i “lic_age15”

Assegurats amb accidents que queden a la mostra: 24

Millor ntree: 350

Table 98: IWE for Speed variable filtering by age35 and lic_age15

	ATT_2	sd	t_stat	p_value	CI_lower	CI_upper
Logit 2-tails	34.2923	499.9276	0.0686	0.9454	-949.0175	1017.602
Tree 2-tails	49.2177	499.0116	0.0986	0.9215	-932.2904	1030.726
Random Forest 2-tails	38.2617	496.8069	0.0770	0.9387	-938.9100	1015.433
Logit 1-tail	34.2923	499.9276	0.0686	0.4727	-790.2424	Inf
Tree 1-tail	49.2177	499.0116	0.0986	0.4607	-773.8062	Inf
Random Forest 1-tail	38.2617	496.8069	0.0770	0.4693	-781.1260	Inf

3.3.2.3.5 Filtratge per “age35” i “power100”

Assegurats amb accidents que queden a la mostra: 31

Millor ntree: 400

Table 99: IWE for Speed variable filtering by age35 and power100

	ATT_2	sd	t_stat	p_value	CI_lower	CI_upper
Logit 2-tails	-47.4329	539.0439	-0.0880	0.9299	-1106.950	1012.0840
Tree 2-tails	-2.6267	532.0388	-0.0049	0.9961	-1048.375	1043.1213
Random Forest 2-tails	-51.9238	534.8453	-0.0971	0.9227	-1103.188	999.3406
Logit 1-tail	-47.4329	539.0439	-0.0880	0.4650	-Inf	841.1478
Tree 1-tail	-2.6267	532.0388	-0.0049	0.4980	-Inf	874.4065
Random Forest 1-tail	-51.9238	534.8453	-0.0971	0.4614	-Inf	829.7358

3.3.2.3.6 Filtratge per “lic_age15” i “power100”

Assegurats amb accidents que queden a la mostra: 36

Millor ntree: 150

Table 100: IWE for Speed variable filtering by lic_age15 and power100

	ATT_2	sd	t_stat	p_value	CI_lower	CI_upper
Logit 2-tails	417.3783	526.8968	0.7921	0.4286	-617.7770	1452.534
Tree 2-tails	344.1550	523.8800	0.6569	0.5115	-685.0735	1373.383
Random Forest 2-tails	411.9911	523.9102	0.7864	0.4320	-617.2968	1441.279
Logit 1-tail	417.3783	526.8968	0.7921	0.2143	-450.8669	Inf
Tree 1-tail	344.1550	523.8800	0.6569	0.2558	-519.1191	Inf
Random Forest 1-tail	411.9911	523.9102	0.7864	0.2160	-451.3328	Inf

3.3.2.3.7 Filtratge per “age35”, “lic_age15” i “power100”

Assegurats amb accidents que queden a la mostra: 13

Millor ntree: 250

Table 101: IWE for Speed variable filtering by age35, lic_age15 and power100

	ATT_2	sd	t_stat	p_value	CI_lower	CI_upper
Logit 2-tails	258.9982	441.5572	0.5866	0.5580	-610.6479	1128.644
Tree 2-tails	245.7872	438.5182	0.5605	0.5756	-617.8737	1109.448
Random Forest 2-tails	247.7198	438.7857	0.5646	0.5729	-616.4679	1111.907
Logit 1-tail	258.9982	441.5572	0.5866	0.2790	-470.0001	Inf
Tree 1-tail	245.7872	438.5182	0.5605	0.2878	-478.1938	Inf
Random Forest 1-tail	247.7198	438.7857	0.5646	0.2864	-476.7029	Inf

3.3.2.4 Variable Urban amb l'efecte de covariables Finalment per a la variable **Urban** anteriorment s'havia obtingut un efecte del tractament de -2 i significatiu mentre les variables **lic_age15** i **woman** són les que es presentaven com a rellevants en el model, totes dues amb un ATT_2 no significatiu. Amb els models semiparamètrics l'efecte del tractament passa a ser no significatiu en tots els cassos, sent el filtratge de la variable **woman** el que es troba més proper de ser-ho.

En general notem que el model semiparamètric dona lloc a resultats generalment no significatius. Pel que a fa a les diferents maneres de construir el model, no es pot concloure quina és la millor, en mostrar pvalors majors o inferiors respecte als altres mètodes en funció del filtratge. Pel cas de la variable **Urban**, el model construït a partir d'un random forest és el que dona lloc a pvalors menors, però això no conclou res ja que per exemple per a la variable **Total** era el tree el que donava lloc a menors pvalors, mentre pel cas de **Night** els resultats varien de forma significativa en funció del filtratge.

3.3.2.4.1 Filtratge per “lic_age15”

Assegurats amb accidents que queden a la mostra: 57

Millor ntree: 400

Table 102: IWE for Urban variable filtering by lic_age15

	ATT_2	sd	t_stat	p_value	CI_lower	CI_upper
Logit 2-tails	531.9211	656.0526	0.8108	0.4178	-756.0804	1819.923
Tree 2-tails	560.4917	653.7891	0.8573	0.3916	-723.0660	1844.049
Random Forest 2-tails	593.5365	656.3586	0.9043	0.3661	-695.0658	1882.139
Logit 1-tail	531.9211	656.0526	0.8108	0.2089	-548.5776	Inf
Tree 1-tail	560.4917	653.7891	0.8573	0.1958	-516.2792	Inf
Random Forest 1-tail	593.5365	656.3586	0.9043	0.1831	-487.4662	Inf

3.3.2.4.2 Filtratge per “woman”

Assegurats amb accidents que queden a la mostra: 155

Millor ntree: 100

Table 103: IWE for Urban variable filtering by woman

	ATT_2	sd	t_stat	p_value	CI_lower	CI_upper
Logit 2-tails	1602.281	1223.633	1.3094	0.1905	-797.4421	4002.004
Tree 2-tails	1529.694	1222.630	1.2512	0.2110	-868.0616	3927.449
Random Forest 2-tails	1584.549	1224.726	1.2938	0.1959	-817.3166	3986.414
Logit 1-tail	1602.281	1223.633	1.3094	0.0953	-411.3454	Inf
Tree 1-tail	1529.694	1222.630	1.2512	0.1055	-482.2814	Inf
Random Forest 1-tail	1584.549	1224.726	1.2938	0.0979	-430.8751	Inf

3.3.2.4.3 Filtratge per “lic_age15” i “woman”

```
## Assegurats amb accidents que queden a la mostra: 28
```

```
## Millor ntree: 400
```

Table 104: IWE for Urban variable filtering by lic_age15 and woman

	ATT_2	sd	t_stat	p_value	CI_lower	CI_upper
Logit 2-tails	177.0829	520.0664	0.3405	0.7336	-845.1192	1199.285
Tree 2-tails	182.1251	519.0999	0.3508	0.7259	-838.1772	1202.428
Random Forest 2-tails	213.8945	520.0784	0.4113	0.6811	-808.3311	1236.120
Logit 1-tail	177.0829	520.0664	0.3405	0.3668	-680.2058	Inf
Tree 1-tail	182.1251	519.0999	0.3508	0.3629	-673.5703	Inf
Random Forest 1-tail	213.8945	520.0784	0.4113	0.3405	-643.4140	Inf

3.3.3 Models semi-paramètrics (IWE) amb dades balancejades

La conclusió de la secció anterior ha estat que no es poden treure resultats significatius principalment perquè les dades es troben molt desbalancejades. Així doncs, a continuació es mirarà què passaria si es treballés amb dades balancejades. S'utilitzarà una tècnica de submostreig per a obtenir el nou conjunt de dades. És a dir, s'ha reduït el nombre de mostres de la classe majoritària (el grup control) per igualar-ho al nombre de mostres de la classe minoritària (el grup tractament). Durant aquest submostreig s'ha de tenir en compte que si s'elimina una persona, s'ha d'eliminar tant la seva fila de $t=1$ com la de $t=2$.

Durant el procediment, ja no es mirarà si queden registres amb $Tr=1$ a la mostra, perquè anteriorment s'ha vist que sí i no s'ha eliminat cap registre d'aquesta tipologia durant el submostreig.

3.3.3.1 Variable Total amb l'efecte de covariables Anteriorment s'havia vist que la filtració per la variable **woman** era la que es trobava més propera a mostrar resultats significatius. En aquest cas, aquesta filtració ha donat lloc a un warning, perquè el model random forest únicament dona lloc a 2 possibles respostes per a la variables dependent. Indicant clarament que els models continuen sense diferenciar de forma significativa. Contràriament, en aquest cas la combinació de la filtració de totes dues variables **age35** i **woman** ha estat la que s'ha trobat més propera a mostrar resultats significatius.

Tot i les explicacions anteriors, es pot confirmar que els resultats milloren en comparació als models amb dades desbalancejades, sobretot pel que fa al tree. Anteriorment, al filtrar per **age35** s'observava que el model únicament donava lloc a 1 nodes (l'arrel). En aquest cas, s'han creat fins a 29 fulles, indicant que com a mínim en aquest cas la diferenciació és major. Per a les altres filtracions, tot i que no de forma tant significativa, les fulles de l'arbre també han augmentat.

3.3.3.1.1 Filtratge per “age35”

```
## Millor ntree: 500
```

Table 105: IWE for Total variable filtering by age35

	ATT_2	sd	t_stat	p_value	CI_lower	CI_upper
Logit 2-tails	42382.61	120049.3	0.3530	0.7247	-195456.8	280222.0
Tree 2-tails	45600.88	125944.8	0.3621	0.7180	-203918.5	295120.3
Random Forest 2-tails	52672.00	114408.2	0.4604	0.6461	-173991.2	279335.2
Logit 1-tail	42382.61	120049.3	0.3530	0.3624	-156713.2	Inf
Tree 1-tail	45600.88	125944.8	0.3621	0.3590	-163272.3	Inf
Random Forest 1-tail	52672.00	114408.2	0.4604	0.3231	-137068.3	Inf

3.3.3.1.2 Filtratge per “woman”

Millor ntree: 150

Table 106: IWE for Total variable filtering by woman

	ATT_2	sd	t_stat	p_value	CI_lower	CI_upper
Logit 2-tails	278107.6	195977.6	1.4191	0.1568	-107411.09	663626.3
Tree 2-tails	287783.2	194995.5	1.4758	0.1409	-95803.49	671369.8
Random Forest 2-tails	243927.4	194373.6	1.2549	0.2104	-138436.02	626290.8
Logit 1-tail	278107.6	195977.6	1.4191	0.0784	-45151.62	Inf
Tree 1-tail	287783.2	194995.5	1.4758	0.0705	-33856.03	Inf
Random Forest 1-tail	243927.4	194373.6	1.2549	0.1052	-76686.11	Inf

3.3.3.1.3 Filtratge per “age35” i “woman”

Millor ntree: 350

Table 107: IWE for Total variable filtering by age35 and woman

	ATT_2	sd	t_stat	p_value	CI_lower	CI_upper
Logit 2-tails	103003.90	67174.66	1.5334	0.1308	-31563.115	237570.9
Tree 2-tails	109117.85	67066.16	1.6270	0.1093	-25231.807	243467.5
Random Forest 2-tails	93191.35	62418.60	1.4930	0.1410	-31848.123	218230.8
Logit 1-tail	103003.90	67174.66	1.5334	0.0654	-9347.219	Inf
Tree 1-tail	109117.85	67066.16	1.6270	0.0547	-3051.794	Inf
Random Forest 1-tail	93191.35	62418.60	1.4930	0.0705	-11205.143	Inf

3.3.3.2 Variable Night amb l'efecte de covariables En aquest cas, els resultats mostrats s'assemblen més als que s'obtenen amb el model TWFE als que s'han obtingut amb l'IWE amb dades desbalancejades, ja que els pvalors indiquen que els resultats són no significatius. Això dona lloc a pensar que els resultats anteriorment obtinguts amb l'IWE no són fiables. Finalment, comentar que altre cop el model random forest ha tornat a donar com a resposta menys de 5 valors, dificultant la regressió que es requereix fer.

3.3.3.2.1 Filtratge per “power100”

Millor ntree: 50

Table 108: IWE for Night variable filtering by power100

	ATT_2	sd	t_stat	p_value	CI_lower	CI_upper
Logit 2-tails	521106.7	211687.2	2.4617	0.0143	104912.4	937301.0
Tree 2-tails	558447.9	209003.6	2.6720	0.0079	147530.0	969365.9
Random Forest 2-tails	526354.3	208085.5	2.5295	0.0118	117241.3	935467.2
Logit 1-tail	521106.7	211687.2	2.4617	0.0071	172080.9	Inf
Tree 1-tail	558447.9	209003.6	2.6720	0.0039	213847.0	Inf
Random Forest 1-tail	526354.3	208085.5	2.5295	0.0059	183267.1	Inf

3.3.3.3 Variable Speed amb l'efecte de covariables En aquest cas els resultats tornen a ser similars als obtinguts anteriorment, en notar que la variable **age35** mostra un efecte del tractament significatiu i negatiu, com també passava amb el model TWFE. A més a més, la variable **power100** mostra un ATT_2 amb un pvalor també proper al 0.05. Es confirma doncs, que tot i que aquests models semi-paramètrics en general no funcionin molt bé, la relació negativa de l'edat amb la velocitat després de tenir un accident és molt clarament significativa, així com la relació que mostra el fet de tenir un cotxe petit, en aquest cas de caràcter positiu,

3.3.3.3.1 Filtratge per “age35”

Millor ntree: 500

Table 109: IWE for Speed variable filtering by age35

	ATT_2	sd	t_stat	p_value	CI_lower	CI_upper
Logit 2-tails	-37.3991	197.4276	-0.1894	0.8501	-428.5388	353.7405
Tree 2-tails	-45.2565	207.1230	-0.2185	0.8274	-455.6046	365.0916
Random Forest 2-tails	-108.6458	188.1504	-0.5774	0.5648	-481.4057	264.1140
Logit 1-tail	-37.3991	197.4276	-0.1894	0.4250	-Inf	290.0247
Tree 1-tail	-45.2565	207.1230	-0.2185	0.4137	-Inf	298.2467
Random Forest 1-tail	-108.6458	188.1504	-0.5774	0.2824	-Inf	203.3922

3.3.3.3.2 Filtratge per “lic_age15”

Millor ntree: 50

Table 110: IWE for Speed variable filtering by lic_age15

	ATT_2	sd	t_stat	p_value	CI_lower	CI_upper
Logit 2-tails	225.9339	165.8384	1.3624	0.1759	-102.8213	554.6891
Tree 2-tails	266.8858	166.2610	1.6052	0.1114	-62.7073	596.4789
Random Forest 2-tails	241.5665	149.3672	1.6173	0.1088	-54.5366	537.6696
Logit 1-tail	225.9339	165.8384	1.3624	0.0880	-49.2283	Inf
Tree 1-tail	266.8858	166.2610	1.6052	0.0557	-8.9777	Inf
Random Forest 1-tail	241.5665	149.3672	1.6173	0.0544	-6.2665	Inf

3.3.3.3 Filtratge per “power100”

Millor ntree: 50

Table 111: IWE for Speed variable filtering by power100

	ATT_2	sd	t_stat	p_value	CI_lower	CI_upper
Logit 2-tails	393.7753	277.6274	1.4184	0.1569	-152.0627	939.6133
Tree 2-tails	424.7615	274.1078	1.5496	0.1220	-114.1566	963.6796
Random Forest 2-tails	387.7393	272.9037	1.4208	0.1562	-148.8115	924.2901
Logit 1-tail	393.7753	277.6274	1.4184	0.0784	-63.9712	Inf
Tree 1-tail	424.7615	274.1078	1.5496	0.0610	-27.1820	Inf
Random Forest 1-tail	387.7393	272.9037	1.4208	0.0781	-62.2189	Inf

3.3.3.4 Filtratge per “age35” i “lic_age15”

Millor ntree: 450

Table 112: IWE for Speed variable filtering by age35 and lic_age15

	ATT_2	sd	t_stat	p_value	CI_lower	CI_upper
Logit 2-tails	92.2057	147.0927	0.6269	0.5337	-203.3881	387.7994
Tree 2-tails	159.1784	139.9971	1.1370	0.2611	-122.1563	440.5130
Random Forest 2-tails	108.9513	127.0237	0.8577	0.3952	-146.3123	364.2149
Logit 1-tail	92.2057	147.0927	0.6269	0.2668	-154.4027	Inf
Tree 1-tail	159.1784	139.9971	1.1370	0.1305	-75.5338	Inf
Random Forest 1-tail	108.9513	127.0237	0.8577	0.1976	-104.0103	Inf

3.3.3.5 Filtratge per “age35” i “power100”

Millor ntree: 250

Table 113: IWE for Speed variable filtering by age35 and power100

	ATT_2	sd	t_stat	p_value	CI_lower	CI_upper
Logit 2-tails	32.5741	131.5043	0.2477	0.8051	-229.9826	295.1308
Tree 2-tails	55.6357	126.3000	0.4405	0.6610	-196.5303	307.8018
Random Forest 2-tails	44.9311	116.3179	0.3863	0.7005	-187.3051	277.1673
Logit 1-tail	32.5741	131.5043	0.2477	0.4026	-186.8106	Inf
Tree 1-tail	55.6357	126.3000	0.4405	0.3305	-155.0668	Inf
Random Forest 1-tail	44.9311	116.3179	0.3863	0.3503	-149.1186	Inf

3.3.3.6 Filtratge per “lic_age15” i “power100”

Millor ntree: 500

Table 114: IWE for Speed variable filtering by lic_age15 and power100

	ATT_2	sd	t_stat	p_value	CI_lower	CI_upper
Logit 2-tails	167.5269	143.6692	1.1661	0.2475	-119.0123	454.0662
Tree 2-tails	184.5400	119.4147	1.5454	0.1268	-53.6250	422.7050
Random Forest 2-tails	151.0480	107.2324	1.4086	0.1634	-62.8204	364.9163
Logit 1-tail	167.5269	143.6692	1.1661	0.1238	-71.9574	Inf
Tree 1-tail	184.5400	119.4147	1.5454	0.0634	-14.5140	Inf
Random Forest 1-tail	151.0480	107.2324	1.4086	0.0817	-27.6993	Inf

3.3.3.3.7 Filtratge per “age35”, “lic_age15” i “power100”

Millor ntree: 50

Table 115: IWE for Speed variable filtering by age35, lic_age15 and power100

	ATT_2	sd	t_stat	p_value	CI_lower	CI_upper
Logit 2-tails	43.6936	103.6236	0.4217	0.6761	-167.3807	254.7679
Tree 2-tails	64.6542	96.9308	0.6670	0.5095	-132.7875	262.0959
Random Forest 2-tails	59.8138	88.0189	0.6796	0.5017	-119.4747	239.1023
Logit 1-tail	43.6936	103.6236	0.4217	0.3380	-131.8332	Inf
Tree 1-tail	64.6542	96.9308	0.6670	0.2548	-99.5359	Inf
Random Forest 1-tail	59.8138	88.0189	0.6796	0.2508	-89.2803	Inf

3.3.3.4 Variable Urban amb l'efecte de covariables Altre cop els resultats per a tots els filtratges són no significatius per a les dues variables provades, així com per a la seva significació. En general, es pot notar que filtrar per més d'1 variable dona lloc a obtenir una significació menor. Això es podria explicar perquè com més filtratge es realitza, menys mostres queden al conjunt de dades i més difícil és que els models captin el comportament darrere les dades.

3.3.3.4.1 Filtratge per “lic_age15”

Millor ntree: 50

Table 116: IWE for Urban variable filtering by lic_age15

	ATT_2	sd	t_stat	p_value	CI_lower	CI_upper
Logit 2-tails	225.9339	165.8384	1.3624	0.1759	-102.8213	554.6891
Tree 2-tails	266.8858	166.2610	1.6052	0.1114	-62.7073	596.4789
Random Forest 2-tails	241.5665	149.3672	1.6173	0.1088	-54.5366	537.6696
Logit 1-tail	225.9339	165.8384	1.3624	0.0880	-49.2283	Inf
Tree 1-tail	266.8858	166.2610	1.6052	0.0557	-8.9777	Inf
Random Forest 1-tail	241.5665	149.3672	1.6173	0.0544	-6.2665	Inf

3.3.3.4.2 Filtratge per “woman”

Millor ntree: 150

Table 117: IWE for Urban variable filtering by woman

	ATT_2	sd	t_stat	p_value	CI_lower	CI_upper
Logit 2-tails	442.0868	298.6881	1.4801	0.1398	-145.4795	1029.6530
Tree 2-tails	419.3769	297.1912	1.4111	0.1591	-165.2447	1003.9985
Random Forest 2-tails	408.5174	296.2434	1.3790	0.1688	-174.2398	991.2747
Logit 1-tail	442.0868	298.6881	1.4801	0.0699	-50.5903	Inf
Tree 1-tail	419.3769	297.1912	1.4111	0.0796	-70.8310	Inf
Random Forest 1-tail	408.5174	296.2434	1.3790	0.0844	-80.1273	Inf

3.3.3.4.3 Filtratge per “lic_age15” i “woman”

Millor ntree: 400

Table 118: IWE for Urban variable filtering by lic_age15 and woman

	ATT_2	sd	t_stat	p_value	CI_lower	CI_upper
Logit 2-tails	86.7743	135.2057	0.6418	0.5234	-183.5862	357.1348
Tree 2-tails	143.5892	138.0187	1.0404	0.3023	-132.3962	419.5747
Random Forest 2-tails	130.9522	126.1088	1.0384	0.3032	-121.2180	383.1224
Logit 1-tail	86.7743	135.2057	0.6418	0.2617	-139.0488	Inf
Tree 1-tail	143.5892	138.0187	1.0404	0.1511	-86.9323	Inf
Random Forest 1-tail	130.9522	126.1088	1.0384	0.1516	-79.6772	Inf